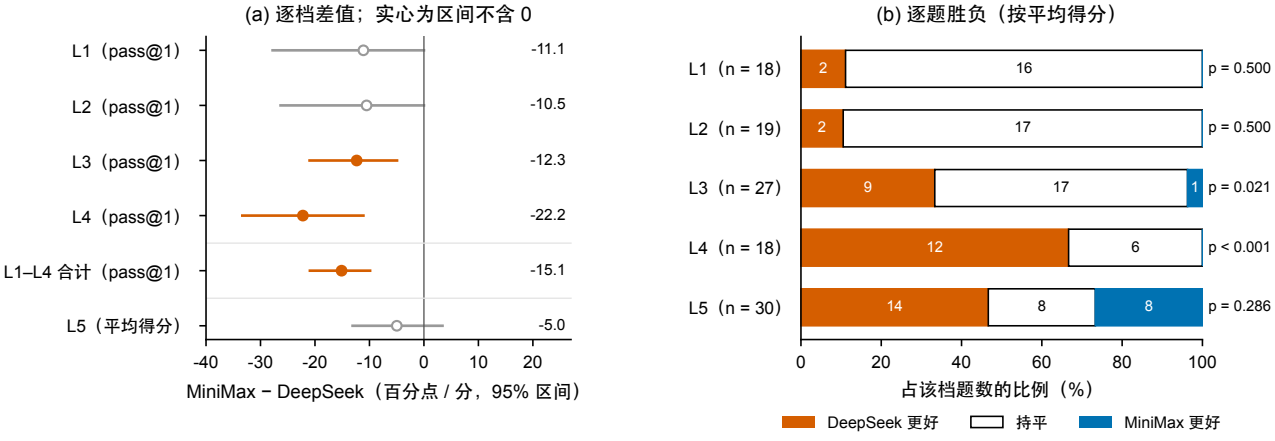
(a) 逐档差值；实心为区间不含 0
L1（pass@1）
L2（pass@1）
L3（pass@1）
L4（pass@1）
L1–L4 合计（pass@1）
L5（平均得分）
-11.1
-10.5
-12.3
-22.2
-15.1
-5.0
-40
-30
-20
-10
0
10
20
MiniMax − DeepSeek（百分点 / 分，95% 区间）
(b) 逐题胜负（按平均得分）
L1（n = 18）
L2（n = 19）
L3（n = 27）
L4（n = 18）
L5（n = 30）
2
16
p = 0.500
2
17
p = 0.500
9
17
1
p = 0.021
12
6
p < 0.001
14
8
8
p = 0.286
0
20
40
60
80
100
占该档题数的比例（%）
DeepSeek 更好
持平
MiniMax 更好