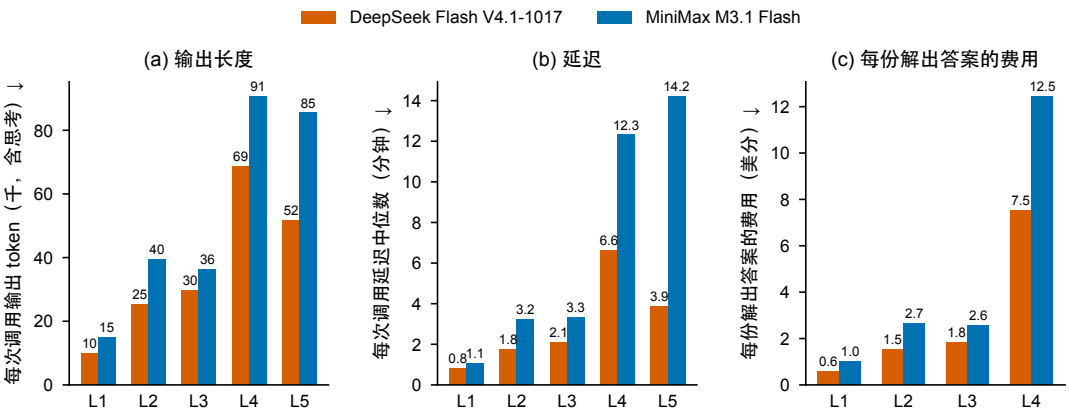
DeepSeek Flash V4.1-1017
MiniMax M3.1 Flash
(a) 输出长度
每次调用输出 token（千，含思考）↓
0
20
40
60
80
10
15
25
40
30
36
69
91
52
85
L1
L2
L3
L4
L5
(b) 延迟
每次调用延迟中位数（分钟）↓
0
2
4
6
8
10
12
14
0.8
1.1
1.8
3.2
2.1
3.3
6.6
12.3
3.9
14.2
L1
L2
L3
L4
L5
(c) 每份解出答案的费用
每份解出答案的费用（美分）↓
0
2
4
6
8
10
12
0.6
1.0
1.5
2.7
1.8
2.6
7.5
12.5
L1
L2
L3
L4