# LiveCodeBench 代码能力评测

Kimi K3.1 Pro / DeepSeek Flash V4.1-1017 / DeepSeek-V4-Pro

2026-10-23（UTC） LiveCodeBench release_v6 最新 35 题（中等 10、困难 25）

## 结论

- 正确率：DS-V4.1-Flash 35/35、DS-V4-Pro 35/35、Kimi K3.1 Pro 34/35（只错 `abc398_g`）。
- 速度：每题延迟中位数：DS-V4.1-Flash 64 秒、Kimi 199 秒、DS-V4-Pro 285 秒。输出速度中位数：DS-V4.1-Flash 179、DS-V4-Pro 134、Kimi 65 token/秒。
- 费用：按 token 计：DS-V4.1-Flash $0.39、DS-V4-Pro $3.33、Kimi $8.57。每道通过题：$0.011 / $0.095 / $0.252。
- 代码：在 13 道能区分性能的题上，Kimi 最快（相对最快倍数几何平均 1.29），DS-V4.1-Flash 2.00，DS-V4-Pro 2.74；DS-V4-Pro 6 题最快但另有 6 题慢 2 倍以上。按 arXiv:2610.19167 的静态质量口径，Kimi 代码最短、Pylint 问题最少、可维护性指数最高（见 5.4）。
- 选型：只看通过率和成本，DS-V4.1-Flash 最优（满分，费用为 Pro 的 12%、Kimi 的 5%，延迟最低）；看代码运行效率，Kimi K3.1 Pro 最好，但输出最慢、费用最高；DS-V4-Pro 满分，但 token 最多、代码效率波动最大。

## 1 模型

| | Kimi K3.1 Pro | DeepSeek-V4.1-Flash | DeepSeek-V4-Pro |
|---|---|---|---|
| API 模型名 | `kimi-k3.1-pro` | `deepseek-flash` | `deepseek-v4-pro` |
| 最近更新 | K3.1 系列首发 | 2026-10-17（1017 版） | 2026-08-13（GA） |
| 规模 | 3T 级，K3（2.8T）后训练 | 552B MoE，激活 8B 输入 / 16B 输出 | 未公布 |
| 权重 | 开放 | 开放，MIT | — |
| 上下文 / 最大输出 | 1M / 默认 131,072 | 1M / 393,216 | 1M / 393,216 |
| 输入 | 文本、图像 | 文本、图像 | 文本 |
| 思考档位 | 恒开；low/high/max，默认 max | low/high/max，默认 high | low/high/max，默认 high |
| 采样 | 固定 T=1.0、top_p=0.95 | 推荐 T=1.0 | — |
| 单价（美元/百万 token，输入 / 缓存 / 输出） | 2 / 0.2 / 10，无峰谷 | 0.3 / 0.006 / 1.2，谷时半价 | 1.32 / 0.044 / 3.96，谷时半价 |

### 1.1 Kimi K3.1 Pro

- 变更：在 K3 上大幅增加后训练算力，覆盖数百个领域联合 RL；重做 RL 框架、长上下文推理、沙箱、rollout 调度。
- 官方提升方向：编程、3D 建模（直接写 Blender / CAD 脚本）、金融研究（内部 Financial Research 比 K3 高 11.6 分）、智能体。
- 安全：中期训练与 RL 数据剔除网络安全内容；xdev-bench-hard pass@3 81.0%（不剔除 90.5%）。
- 高速版 `kimi-k3.1-pro-highspeed`：速度 2–3 倍，价格 2 倍。K2 系列 2026 年底下线。
- 使用限制：充值 ≥1 美元解锁；累计充值决定并发 / TPM；temperature、top_p、n、penalty 不可传。
- 官方文档中的编程基准分数为占位符（"[xx.x%]"），无可引用数据。

### 1.2 DeepSeek-V4.1-Flash

- 2026-09-10 发布：20 层因果编码器 + 20 层解码器；MoE 1 共享 + 384 路由专家，每 token 激活 6 个；KV 缓存 890 字节/token，HBM 为上一代 1/4、SSD 为 1/8；原生视觉；降价；V4-Flash 下线。
- 2026-10-17 更新为 1017 版（新 / 旧）：Terminal-Bench 4.0 42.3 / 31.2，DeepSWE v1.1 77.0 / 74.2，ProgramBench 29.1 / 20.3，NL2Repo 68.2 / 65.4，HLE 42.6 / 36.8；输出更短、耗时更少；价格与调用方式不变。
- Codeforces 3471（max 档；同表 V4-Pro 3348）。输出单价为 V4-Pro 的 30%、Kimi K3.1 Pro 的 12%。

### 1.3 DeepSeek-V4-Pro

- 2026-04-24 首发；2026-08-13 GA：HLE 42.7 / 60.0（无 / 有工具），Terminal-Bench 2.1 87.9，DeepSWE 62.7，NL2Repo 61.5，Toolathlon-Verified 74.1；引入 low/high/max 三档；2026-08-16 起峰谷定价。
- V4.1-Flash 新闻稿称 9 月 14 日起该模型名改由 V4.1-Flash 承接，更新日志称继续提供、计费不变。本次 API 返回模型名 `deepseek-v4-pro`，按 V4-Pro 单价扣费。
- 仅文本输入；单价为 V4.1-Flash 的 3.3 倍；DeepSeek 自报多数基准低于 V4.1-Flash。

# 2 评测方法

| 项目 | 设置 |
|---|---|
| 评测集 | LiveCodeBench release_v6（ICLR 2025），官方提示词与官方测试数据，全部测试通过才算通过 |
| 指标 | pass@1，每题 1 次 |
| 调用 | 官方 API；`BAI-AI-Lab/codingBench`，`cb livecodebench` |
| 思考档位 | 各模型默认（Kimi max，DeepSeek high） |
| 采样 | DeepSeek：temperature 0.2（LCB 官方）；Kimi：固定 1.0 |
| 输出上限 | DeepSeek 262,144；Kimi 131,072（默认）；全部回答正常结束（finish_reason=stop），无截断 |
| 并发 | V4.1-Flash 16，V4-Pro 8，Kimi 1–4；延迟含服务端排队 |
| 计量 | 每次调用记录起止时间与服务端返回的 token（含思考） |
| 费用 | 官方单价 × token，DeepSeek 按调用时段区分峰谷 |
| 判题 | AtCoder：每份答案作为独立 Python 进程，用真实标准输入输出运行全部官方测试（每个测试 6 秒），逐 token 比对；`abc397_d`、`arc195_c` 用按题意编写的校验器（前者第 41 个测试的标准答案不满足题意，后者允许任意合法构造）。LeetCode：LCB 的函数调用判题 |

# 3 评测题目

## 3.1 分布

release_v6 最新 100 题中，按难度各取最新：中等 10、困难 25；发布于 2025-03-15 至 2025-04-06。

| 难度 | AtCoder | LeetCode | 合计 |
|---|---|---|---|
| 中等 | 7 | 3 | 10 |
| 困难 | 19 | 6 | 25 |
| 合计 | 26 | 9 | 35 |

| 来源 | 题数 | 形式 |
|---|---|---|
| AtCoder ABC 397–400 | 17 | 完整程序，标准输入输出 |
| AtCoder ARC 195–196 | 9 | 完整程序，标准输入输出 |
| LeetCode 周赛 / 双周赛 | 9 | 补全给定 Python 函数 |

## 3.2 示例

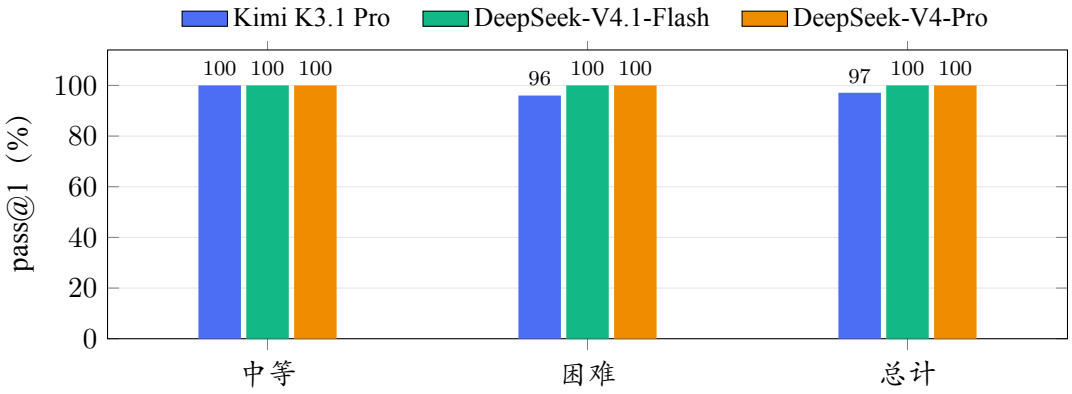
| 题目 | 内容 |
|---|---|
| **ABC 400 C**<br>“2^a b^2”<br>中等，<br>2025-04-05 | **题意**：$X = 2^a b^2$（$a, b \geq 1$）为好数；给定 $N \leq 10^{18}$，求 $[1, N]$ 内好数个数。$N = 20$ 时为 5（2, 4, 8, 16, 18）。<br>**考点**：好数恰为 $2m^2$ 或 $4m^2$ 两类且互不重叠，答案 $\lfloor\sqrt{N/2}\rfloor + \lfloor\sqrt{N/4}\rfloor$；须用整数开方，浮点 `sqrt` 在 $10^{18}$ 附近出错。<br>**结果**：Kimi ✓，2.3k token，35 秒；DS-Flash ✓，1.3k token，7 秒；DS-Pro ✓，3.4k token，25 秒 |
| **ARC 195 D**<br>“Swap and Erase”<br>困难，<br>2025-03-23 | **题意**：可交换相邻元素，或删除开头一段全部相等的前缀；求删空序列的最少操作数。$T \leq 10^5$，$\sum N \leq 2 \times 10^5$。<br>**考点**：交换与删除的组合优化，须近线性时间。样例：$(1, 1, 2, 1, 2)$ 为 3（1 次交换 + 2 次删除），$(4, 2, 1, 3)$ 为 4（不交换）。<br>**结果**：Kimi ✓，86.5k token，1089 秒；DS-Flash ✓，81.0k token，475 秒；DS-Pro ✓，110.3k token，815 秒 |
| **LeetCode 3801**<br>“Count Beautiful Numbers”<br>困难，<br>2025-03-15 | **题意**：各位数字之积能被各位数字之和整除的正整数为美丽数；给定 $1 \leq l \leq r < 10^9$，求区间内个数。补全 `beautifulNumbers(self, l, r)`。<br>**考点**：数位 DP；含 0 时积为 0 必满足，否则积为 $2^a 3^b 5^c 7^d$，状态有限；暴力枚举超时。<br>**结果**：Kimi ✓，6.4k token，99 秒；DS-Flash ✓，3.8k token，22 秒；DS-Pro ✓，66.3k token，474 秒 |

# 4 评测结果

## 4.1 总表

| 指标 | Kimi K3.1 Pro | DS-V4.1-Flash | DS-V4-Pro |
|---|---|---|---|
| 通过（总计 35）↑ | 34（97.1%） | **35（100.0%）** | **35（100.0%）** |
| 中等（10）↑ | **10** | **10** | **10** |
| 困难（25）↑ | 24 | **25** | **25** |
| AtCoder（26）↑ | 25 | **26** | **26** |
| LeetCode（9）↑ | **9** | **9** | **9** |
| 有效运行时间（分钟）↓ | 143 | **9** | 49 |
| 每题延迟中位数（秒）↓ | 199 | **64** | 285 |
| 每题延迟 P90（秒）↓ | 1089 | **327** | 834 |
| 每题延迟最长（秒）↓ | 1888 | **475** | 1378 |
| 输出速度中位数（token/秒）↑ | 65 | **179** | 134 |
| 输出 token 合计↓ | 852k | **644k** | 1.67M |
| 其中思考 token 占比 | 98% | 97% | 99% |
| 每题输出 token 中位数↓ | 14k | **12k** | 38k |
| 输入 token 合计（缓存命中） | 24k（0k） | 22k（16k） | 24k（0k） |
| 费用（美元，按 token 计）↓ | $8.57 | **$0.39** | $3.33 |
| 每道通过题的费用（美元）↓ | $0.252 | **$0.011** | $0.095 |

↑越大越好，↓越小越好，没有箭头的行只作描述；粗体为该行最优。1 题 = 2.9 个百分点。有效运行时间 = 成功请求覆盖的时长。



## 4.2 按难度

| 难度 | 模型 | 通过↑ | 延迟中位数（秒）↓ | 平均输出 token↓ | 最多输出 token↓ |
|---|---|---|---|---|---|
| 中等 | Kimi K3.1 Pro | 10/10 | 34 | 7k | 27k |
| 中等 | DeepSeek-V4.1-Flash | 10/10 | 8 | 10k | 49k |
| 中等 | DeepSeek-V4-Pro | 10/10 | 28 | 16k | 64k |
| 困难 | Kimi K3.1 Pro | 24/25 | 280 | 31k | 119k |
| 困难 | DeepSeek-V4.1-Flash | 25/25 | 79 | 22k | 81k |
| 困难 | DeepSeek-V4-Pro | 25/25 | 388 | 61k | 174k |

## 4.3 分析

- 唯一的错误：Kimi `abc398_g`（博弈题），思考 11.9 万 token、耗时 31 分钟后，在 4/43 个测试上答案错误。这题 DS-V4.1-Flash 用 6.3 万 token、DS-V4-Pro 用 17.4 万 token 都做对了。
- 推理量：每题输出 token 中位数 DS-V4.1-Flash 12k、Kimi 14k、DS-V4-Pro 38k；困难题平均分别为 22k、31k、61k。DS-V4-Pro 多用的 token 没有换来更多通过题。

## 4.4 逐题结果

每个模型：结果 / 输出 token（含思考，越小越好）/ 延迟（秒，越小越好）。† 评测中 API 返回的内容与题目无关，人工另行调用验证正确，按通过计。

| 题号 | 题目 | 难度 | Kimi K3.1 Pro | | DS-V4.1-Flash | | DS-V4-Pro | |
|---|---|---|---|---|---|---|---|---|
| `abc398_b` | Full House 3 | 中 | ✓ 0.9k | 15 | ✓ 0.3k | 3 | ✓ 1.0k | 7 |
| `abc398_c` | Uniqueness | 中 | ✓ 0.4k | 5 | ✓ 0.4k | 3 | ✓ 0.4k | 4 |
| `arc195_a` | Twice Subsequence | 中 | ✓ 2.2k | 34 | ✓ 2.9k | 16 | ✓ 18.4k | 144 |
| `abc399_c` | Make it Forest | 中 | ✓ 0.5k | 8 | ✓ 0.5k | 3 | ✓ 0.4k | 4 |
| `abc399_d` | Switch Seats | 中 | ✓ 25.4k | 409 | ✓ 26.8k | 149 | ✓ 38.2k | 282 |
| `abc400_c` | 2^a b^2 | 中 | ✓ 2.3k | 35 | ✓ 1.3k | 7 | ✓ 3.4k | 25 |
| `abc400_d` | Takahashi the Wall Breaker | 中 | ✓ 26.7k | 416 | ✓ 49.0k | 290 | ✓ 63.9k | 544 |
| `3809` | properties-graph | 中 | ✓ 0.6k | 10 | ✓ 0.4k | 3 | ✓ 1.1k | 8 |
| `3805` | maximize-active-section-w… | 中 | ✓ 7.5k | 94 | ✓ 13.4k | 75 | ✓ 27.9k | 208 |
| `3793` | longest-palindrome-after-… | 中 | ✓ 2.7k | 44 | ✓ 1.5k | 9 | ✓ 4.0k | 30 |
| `abc397_d` | Cubes | 难 | ✓ 3.3k | 49 | ✓ 5.0k | 25 | ✓ 26.4k | 179 |
| `abc397_e` | Path Decomposition of a T… | 难 | ✓ 26.7k | 451 | ✓ 15.6k | 95 | ✓ 42.5k | 332 |
| `abc397_f` | Variety Split Hard | 难 | ✓ 64.0k | 944 | ✓ 21.4k | 107 | ✓ 55.9k | 403 |
| `abc397_g` | Maximize Distance | 难 | ✓ 33.1k | 423 | ✓ 14.5k | 76 | ✓ 55.8k | 423 |
| `abc398_d` | Bonfire | 难 | ✓ 4.4k | 74 | ✓ 2.8k | 16 | ✓ 10.8k | 80 |
| `abc398_f` | ABCBA | 难 | ✓ 6.4k | 97 | ✓ 1.7k | 9 | ✓ 38.2k | 285 |
| `abc398_g` | Not Only Tree Game | 难 | ✗答案错误 118.7k | 1888 | ✓ 63.4k | 327 | ✓ 174.0k | 1378 |
| `arc195_b` | Uniform Sum | 难 | ✓ 54.6k | 924 | ✓ 16.7k | 96 | ✓ 55.7k | 454 |
| `arc195_c` | Hamiltonian Pieces | 难 | ✓ 20.9k | 322 | ✓ 22.4k | 120 | ✓ 64.1k | 453 |
| `arc195_d` | Swap and Erase | 难 | ✓ 86.5k | 1089 | ✓ 81.0k | 475 | ✓ 110.3k | 815 |
| `arc195_e` | Random Tree Distance | 难 | ✓ 11.7k | 176 | ✓ 11.6k | 64 | ✓ 37.9k | 256 |
| `abc399_e` | Replace | 难 | ✓† 2.8k | 51 | ✓ 26.3k | 164 | ✓ 55.0k | 463 |
| `abc399_f` | Range Power Sum | 难 | ✓ 2.5k | 38 | ✓ 2.5k | 12 | ✓ 6.6k | 51 |
| `abc400_e` | Ringo's Favorite Numbers 3 | 难 | ✓ 3.1k | 47 | ✓ 3.1k | 16 | ✓ 10.2k | 79 |

| 题号 | 题目 | 难度 | Kimi K3.1 Pro | | DS-V4.1-Flash | | DS-V4-Pro | |
|---|---|---|---|---|---|---|---|---|
| abc400_g | Patisserie ABC 3 | 难 ✓ | 43.4k | 735 ✓ | 55.0k | 334 ✓ | 112.7k | 941 |
| arc196_a | Adjacent Delete | 难 ✓ | 33.4k | 536 ✓ | 18.3k | 98 ✓ | 48.3k | 351 |
| arc196_b | Torus Loop | 难 ✓ | 16.9k | 280 ✓ | 22.7k | 121 ✓ | 67.9k | 496 |
| arc196_c | Strongly Connected | 难 ✓ | 105.4k | 1730 ✓ | 76.8k | 439 ✓ | 164.2k | 1221 |
| arc196_d | Roadway | 难 ✓ | 68.1k | 1230 ✓ | 43.0k | 248 ✓ | 110.4k | 834 |
| 3784 | longest-common-prefix-of-… | 难 ✓ | 20.5k | 296 ✓ | 8.9k | 50 ✓ | 49.4k | 368 |
| 3801 | count-beautiful-numbers | 难 ✓ | 6.4k | 99 ✓ | 3.8k | 22 ✓ | 66.3k | 474 |
| 3744 | minimum-operations-to-mak… | 难 ✓ | 14.1k | 220 ✓ | 5.9k | 33 ✓ | 34.9k | 250 |
| 3765 | minimum-cost-to-divide-ar… | 难 ✓ | 6.5k | 80 ✓ | 3.5k | 19 ✓ | 35.1k | 259 |
| 3717 | minimum-operations-to-mak… | 难 ✓ | 14.1k | 214 ✓ | 7.6k | 40 ✓ | 30.1k | 215 |
| 3777 | maximum-product-of-subseq… | 难 ✓ | 15.2k | 199 ✓ | 13.9k | 79 ✓ | 50.8k | 388 |

# 5 代码性能与静态指标

## 5.1 测量方法

| 项目 | 设置 |
|---|---|
| 对象 | 通过的答案（Kimi 33 份，不含 abc398_g、abc399_e；DeepSeek 各 35 份） |
| 运行 | 每次运行都是一个全新的 Python 3.11 进程（LCB 环境），绑定到单个 CPU 核；共 11,124 次，输出全部正确 |
| 计时 | AtCoder：进程 CPU 时间（rusage）扣除启动基线 25.7 ms；LeetCode：只计 Solution 方法调用的 CPU 时间 |
| 内存 | 进程峰值常驻内存（ru_maxrss）；空程序为 12.1 MB |
| 重复 | 每个测试 3 次、三个模型轮流先跑，取中位数；同一测试 3 次的离散度中位数 2.0%，P90 6.4% |
| 可比题 | 最慢答案扣除启动后仍 ≥ 0.1 秒的题，共 13 题；其余 22 题官方测试太小，耗时主要是启动开销，不比较 |

## 5.2 逐题性能

| 题号 | 难度 | 类型 | 最大输入 KB | Kimi K3.1 Pro | | DS-V4.1-Flash | | DS-V4-Pro | |
|---|---|---|---|---|---|---|---|---|---|
| | | | | CPU 秒↓ | MB↓ | CPU 秒↓ | MB↓ | CPU 秒↓ | MB↓ |
| abc399_c | 中 | AC | 2517 | 0.23 | 50 | 0.26 | 22 | **0.22** | 44 |
| abc399_d | 中 | AC | 1758 | 0.15 | 38 | 0.28 (2.3×) | 48 | **0.12** | 48 |
| 3717 | 难 | LC | 830 | **1.00** | 37 | 1.40 | 41 | 1.21 | 37 |
| 3744 | 难 | LC | 2137 | 0.27 (5.0×) | 32 | 0.67 (12.5×) | 32 | **0.05** | 32 |
| 3765 | 难 | LC | 9 | **0.14** | 16 | 0.14 | 16 | 1.24 (9.1×) | 16 |
| 3784 | 难 | LC | 391 | 0.11 (2.2×) | 22 | 0.06 | 28 | **0.05** | 22 |
| 3801 | 难 | LC | 0 | **0.11** | 26 | 0.11 | 26 | 0.93 (8.3×) | 18 |
| abc397_d | 难 | AC | 0 | 0.14 | 12 | 0.14 | 12 | **0.11** | 12 |
| abc397_g | 难 | AC | 0 | **0.01** | 14 | 0.02 (2.5×) | 14 | 0.23 (36.1×) | 14 |
| abc400_e | 难 | AC | 0 | 0.43 | 36 | 0.39 | 32 | **0.26** | 24 |
| abc400_g | 难 | AC | 2773 | **0.16** | 32 | 0.27 | 40 | 1.45 (9.3×) | 40 |
| arc195_b | 难 | AC | 37 | **0.15** | 14 | 1.30 (8.5×) | 91 | 0.96 (6.3×) | 119 |
| arc196_d | 难 | AC | 80 | **0.06** | 16 | 0.13 (2.1×) | 16 | 0.15 (2.5×) | 18 |

↓越小越好。CPU 秒为最慢一个测试的 CPU 时间（3 次取中位数，扣除启动）；粗体为该题最快；括号内为相对最快者的倍数（≥ 2 时标出）。MB 为该题各测试中的最大峰值内存。AC = AtCoder，LC = LeetCode。

## 5.3 汇总

| 模型 | 相对最快倍数↓（几何平均） | 最快↑（题） | 慢 ≥ 2 倍↓（题） | CPU 合计↓（秒） | 峰值内存（MB）↓ 中位数 | 最大 |
|---|---|---|---|---|---|---|
| Kimi | **1.29** | 7 | 2 | 16.7 | 26 | 50 |
| DS-Flash | 2.00 | 0 | 5 | 29.7 | 28 | 91 |
| DS-Pro | 2.74 | 6 | 6 | 52.8 | 24 | 119 |

↑越大越好，↓越小越好。基于 13 道可比题（三个模型都通过）。CPU 合计为这些题所有测试的 CPU 时间之和。“最快”按严格最小值计；有 3 题第二名与最快相差不到 5%（噪声范围内）：3765、3801 上 Flash 比 Kimi 慢 3% 和 2%，abc399_c 上 Kimi 比 Pro 慢 3%。按并列计，Flash 的最快题数为 2。

- arc195_b（Flash 慢 8.5 倍，内存 91 MB）：Flash 枚举 A、B 所有不同取值的两两组合，复杂度 $O(U \cdot V)$，并把重复的和逐个展开存入列表；Kimi 先按通配数量选出必须参与配对的候选值，再用二分查找限定候选和，0.15 秒。
- abc400_g（Pro 慢 9.3 倍）：Pro 为每组数据建图跑最小费用流；Kimi 用“取最大值后只修正奇偶”的贪心，每类只保留前两个候选，$O(N \log N)$。
- 3765（Pro 慢 9.1 倍）：Pro 按子数组个数分层、每层做凸包优化，$O(n^2 \log n)$；Kimi 直接用 $O(n^2)$ 的后缀 DP。
- 3801（Pro 慢 8.3 倍）：Pro 对每个可能的数位和 $S$ 单独建 [剩余位数][和][积 mod $S$] 计数表；Kimi 用以（位置，和，积）为状态的记忆化数位 DP。

- abc397_g：Pro 0.23 秒、Kimi 0.01 秒，倍数大但绝对值都很小。
- 全部可比题的最慢测试都在 1.5 秒以内，未接近 AtCoder 常见的 2 秒时限；但评测机器与 AtCoder 不同，不能据此判断能否在原平台通过。

## 5.4 静态代码质量

按 Huang 等（arXiv:2610.19167，ICECCS 2026）的口径：Pylint 3.3.5（默认配置）、Radon 6.0.1（命令行）、SonarQube 10.4 Community（本机部署，默认质量配置）；每份答案原样分析，不补 import；不合成总分。Kimi 的 abc399_e 没有代码，不计入；“全部答案”与“仅通过”只差 Kimi 的 abc398_g 一份。

| | | | Pylint | | | | | | SonarQube | | |
|---|---|---|---|---|---|---|---|---|---|---|---|
| 模型 | 难度 | 份数 | Pylint 合计↓ | C↓ | R↓ | W↓ | E↓ | 得分↑ | 可维护性↓ | 可靠性↓ | 安全↓ |
| 全部答案 | | | | | | | | | | | |
| Kimi | 中等 | 10 | 3.90 | 3.50 | 0.40 | 0.00 | 0.00 | 7.87 | 0.60 | 0.00 | 0.00 |
| | 困难 | 24 | 7.83 | 4.62 | 1.62 | 1.54 | 0.04 | 8.37 | 0.96 | 0.00 | 0.00 |
| | 合计 | 34 | **6.68** | **4.29** | **1.26** | 1.09 | 0.03 | **8.22** | **0.85** | **0.00** | **0.00** |
| DS-Flash | 中等 | 10 | 7.10 | 6.20 | 0.80 | 0.10 | 0.00 | 7.45 | 0.70 | 0.00 | 0.00 |
| | 困难 | 25 | 10.44 | 7.04 | 2.84 | 0.56 | 0.00 | 8.16 | 1.56 | 0.00 | 0.00 |
| | 合计 | 35 | 9.49 | 6.80 | 2.26 | **0.43** | **0.00** | 7.96 | 1.31 | **0.00** | **0.00** |
| DS-Pro | 中等 | 10 | 6.10 | 5.40 | 0.60 | 0.10 | 0.00 | 7.39 | 0.70 | 0.00 | 0.00 |
| | 困难 | 25 | 15.24 | 10.44 | 2.92 | 1.88 | 0.00 | 7.81 | 3.12 | 0.00 | 0.00 |
| | 合计 | 35 | 12.63 | 9.00 | 2.26 | 1.37 | **0.00** | 7.69 | 2.43 | **0.00** | **0.00** |
| 仅通过的答案 | | | | | | | | | | | |
| Kimi | 中等 | 10 | 3.90 | 3.50 | 0.40 | 0.00 | 0.00 | 7.87 | 0.60 | 0.00 | 0.00 |
| | 困难 | 23 | 7.96 | 4.70 | 1.65 | 1.57 | 0.04 | 8.35 | 0.91 | 0.00 | 0.00 |
| | 合计 | 33 | **6.73** | **4.33** | **1.27** | 1.09 | 0.03 | **8.20** | **0.82** | **0.00** | **0.00** |
| DS-Flash | 中等 | 10 | 7.10 | 6.20 | 0.80 | 0.10 | 0.00 | 7.45 | 0.70 | 0.00 | 0.00 |
| | 困难 | 25 | 10.44 | 7.04 | 2.84 | 0.56 | 0.00 | 8.16 | 1.56 | 0.00 | 0.00 |
| | 合计 | 35 | 9.49 | 6.80 | 2.26 | **0.43** | **0.00** | 7.96 | 1.31 | **0.00** | **0.00** |
| DS-Pro | 中等 | 10 | 6.10 | 5.40 | 0.60 | 0.10 | 0.00 | 7.39 | 0.70 | 0.00 | 0.00 |
| | 困难 | 25 | 15.24 | 10.44 | 2.92 | 1.88 | 0.00 | 7.81 | 3.12 | 0.00 | 0.00 |
| | 合计 | 35 | 12.63 | 9.00 | 2.26 | 1.37 | **0.00** | 7.69 | 2.43 | **0.00** | **0.00** |

每份答案平均。↑越大越好，↓越小越好。C 规范、R 重构、W 警告、E 错误，均为问题条数；得分 0–10；SonarQube 为可维护性、可靠性、安全三类问题数。粗体为合计行中最优。每份答案都有一条“缺少末尾换行”(C0304)，来自答案提取，三个模型相同。Kimi 的 1 个 E 是 arc196_c 导入 numpy（分析环境未安装 numpy）。

| 模型 | 难度 | 份数 | CC↓ | MI↑ | Func | LOC | LLOC | SLOC | CMT | BLN |
|---|---|---|---|---|---|---|---|---|---|---|
| 全部答案 | | | | | | | | | | |
| Kimi | 中等 | 10 | 8.5 | 65.3 | 1.2 | 33.6 | 24.8 | 24.8 | 1.7 | 7.2 |
| | 困难 | 24 | 17.7 | 59.8 | 2.2 | 82.2 | 59.1 | 60.8 | 5.5 | 16.2 |
| | 合计 | 34 | **15.0** | **61.4** | 1.9 | 67.9 | 49.0 | 50.2 | 4.4 | 13.5 |
| DS-Flash | 中等 | 10 | 11.8 | 56.4 | 1.2 | 42.6 | 32.7 | 32.0 | 0.9 | 9.7 |
| | 困难 | 25 | 18.6 | 50.1 | 1.5 | 93.6 | 71.3 | 71.0 | 3.6 | 19.9 |
| | 合计 | 35 | 16.7 | 51.9 | 1.4 | 79.0 | 60.3 | 59.8 | 2.8 | 17.0 |
| DS-Pro | 中等 | 10 | 12.2 | 56.2 | 1.3 | 37.0 | 30.9 | 30.3 | 0.5 | 6.2 |
| | 困难 | 25 | 21.3 | 54.2 | 2.0 | 101.4 | 80.5 | 80.0 | 5.3 | 17.1 |
| | 合计 | 35 | 18.7 | 54.8 | 1.8 | 83.0 | 66.3 | 65.8 | 3.9 | 14.0 |
| 仅通过的答案 | | | | | | | | | | |
| Kimi | 中等 | 10 | 8.5 | 65.3 | 1.2 | 33.6 | 24.8 | 24.8 | 1.7 | 7.2 |
| | 困难 | 23 | 17.9 | 59.9 | 2.3 | 83.3 | 59.9 | 61.7 | 5.7 | 16.3 |
| | 合计 | 33 | **15.0** | **61.5** | 1.9 | 68.2 | 49.2 | 50.5 | 4.5 | 13.5 |
| DS-Flash | 中等 | 10 | 11.8 | 56.4 | 1.2 | 42.6 | 32.7 | 32.0 | 0.9 | 9.7 |
| | 困难 | 25 | 18.6 | 50.1 | 1.5 | 93.6 | 71.3 | 71.0 | 3.6 | 19.9 |
| | 合计 | 35 | 16.7 | 51.9 | 1.4 | 79.0 | 60.3 | 59.8 | 2.8 | 17.0 |
| DS-Pro | 中等 | 10 | 12.2 | 56.2 | 1.3 | 37.0 | 30.9 | 30.3 | 0.5 | 6.2 |
| | 困难 | 25 | 21.3 | 54.2 | 2.0 | 101.4 | 80.5 | 80.0 | 5.3 | 17.1 |
| | 合计 | 35 | 18.7 | 54.8 | 1.8 | 83.0 | 66.3 | 65.8 | 3.9 | 14.0 |

每份答案平均。↑越大越好，↓越小越好；没有箭头的列只描述规模，不分好坏。CC 为圈复杂度，`radon cc -j` 全部条目之和（类与它的方法各计一条）；难题本身需要更多分支，且代码越长 CC 越高，宜结合每 100 有效行的密度看。MI 为可维护性指数，0–100，20 以上为易维护；Func 为条目数；LOC、LLOC、SLOC、CMT、BLN 分别为总行、逻辑行、有效行、注释行、空行。

| | | | Pylint | | | | | Radon | | SonarQube | | |
|---|---|---|---|---|---|---|---|---|---|---|---|---|
| 模型 | 难度 | 份数 | Pylint 合计↓ | C↓ | R↓ | W↓ | E↓ | CC↓ | Func | 可维护性↓ | 可靠性↓ | 安全↓ |
| Kimi | 中等 | 10 | 15.73 | 14.11 | 1.61 | 0.00 | 0.00 | 34.27 | 4.84 | 2.42 | 0.00 | 0.00 |
| | 困难 | 23 | 12.90 | 7.61 | 2.68 | 2.54 | 0.07 | 28.96 | 3.66 | 1.48 | 0.00 | 0.00 |
| | 合计 | 33 | **13.32** | **8.58** | **2.52** | 2.16 | 0.06 | 29.75 | 3.84 | **1.62** | **0.00** | **0.00** |
| DS-Flash | 中等 | 10 | 22.19 | 19.38 | 2.50 | 0.31 | 0.00 | 36.88 | 3.75 | 2.19 | 0.00 | 0.00 |
| | 困难 | 25 | 14.71 | 9.92 | 4.00 | 0.79 | 0.00 | 26.21 | 2.14 | 2.20 | 0.00 | 0.00 |
| | 合计 | 35 | 15.85 | 11.37 | 3.77 | **0.72** | **0.00** | **27.84** | 2.39 | 2.20 | **0.00** | **0.00** |
| DS-Pro | 中等 | 10 | 20.13 | 17.82 | 1.98 | 0.33 | 0.00 | 40.26 | 4.29 | 2.31 | 0.00 | 0.00 |
| | 困难 | 25 | 19.04 | 13.04 | 3.65 | 2.35 | 0.00 | 26.64 | 2.45 | 3.90 | 0.00 | 0.00 |
| | 合计 | 35 | 19.18 | 13.67 | 3.43 | 2.08 | **0.00** | 28.43 | 2.69 | 3.69 | **0.00** | **0.00** |

仅通过的答案，每 100 有效行（SLOC）的数量：各题之和 ÷ SLOC 之和 × 100。↓越小越好；Func 只描述代码拆分方式，不分好坏。

- Pylint（Kimi / DS-Flash / DS-Pro，每份）：问题 6.73 / 9.49 / 12.63，得分 8.20 / 7.96 / 7.69。DS-Pro 最多，主要是命名不合规（C0103，共 25 / 110 / 174 条）。
- 警告（W）Kimi 每份 1.09，高于 DS-Flash 的 0.43，但集中在 2 份答案的循环内闭包（W0640 33 条）；DS-Pro 的 W0640 有 34 条，集中在 1 份。未使用的变量（W0612）：Kimi 0、DS-Flash 3、DS-Pro 8 条。
- Radon（每份）：Kimi 代码最短（SLOC 50.5 / 59.8 / 65.8）、可维护性指数最高（61.5 / 51.9 / 54.8）、圈复杂度最低（15.0 / 16.7 / 18.7）。
- 按每 100 SLOC：Pylint 问题 13.32 / 15.85 / 19.18，排序不变；但 Kimi 的圈复杂度密度（29.75 / 27.84 / 28.43）和函数密度（3.84 / 2.39 / 2.69）最高，即代码更短、分支和函数更密。
- SonarQube（每份）：可维护性问题 0.82 / 1.31 / 2.43，三个模型的可靠性和安全问题都是 0。主要是函数认知复杂度过高（S3776，共 18 / 21 / 22 条）和局部变量命名不合规（S117，0 / 8 / 33 条）；函数命名（S100，9 / 9 / 9 条）来自 LeetCode 规定的驼峰式方法名。

补充（不属于上述口径）：

| 模型 | 嵌套深度中位数↓ | 嵌套深度最大↓ | AtCoder 读入方式（题数） |
|---|---|---|---|
| Kimi | 5 | 7 | buffer.read 20、read 3、buffer.readline 1 |
| DS-Flash | 5 | 10 | buffer.read 17、readline 4、buffer.readline 2、read 1 |
| DS-Pro | 4 | 11 | buffer.read 14、read 6、readline 3、buffer.readline 1 |

基于 33 道三个模型都通过的题。嵌套深度为语法树中复合语句的最大嵌套层数，越小越好；读入方式只作描述。Kimi 采样温度 1.0、DeepSeek 0.2，风格差异部分来自采样。

## 6 局限

- 35 题、每题 1 次：相差 1–2 题不显著；两个 DeepSeek 模型均为满分，这批题已不足以区分二者。
- 采样温度不同：DeepSeek 0.2，Kimi 固定 1.0。
- 延迟受并发和服务端负载影响。
- 题目早于三个模型发布，不排除训练数据污染。
- 成绩依赖本评测的判题程序和校验器。
- Kimi `abc399_e` 按人工另行调用的结果计为通过，未在本评测流程中复现。

## 来源

- Kimi：`https://platform.kimi.ai/docs/guide/kimi-k3-1-pro-quickstart`，`https://platform.kimi.ai/docs/models`，`https://platform.kimi.ai/docs/pricing/chat`
- DeepSeek：`https://api-docs.deepseek.com/updates/`，`https://www.deepseek.com/en/news/deepseek-v4-1-flash/`，`https://huggingface.co/deepseek-ai/DeepSeek-V4.1-Flash`，`https://api-docs.deepseek.com/quick_start/pricing`
- 上下文、最大输出、默认档位：两家 API `/v1/models`（2026-10-23）
- LiveCodeBench：`https://livecodebench.github.io`

由 Albert Huang 创建于 2026-10-23