LiveCodeBench 代码能力评测

Kimi K3.1 Pro / DeepSeek-V4.1-Flash / DeepSeek-V4-Pro

2026-10-23（UTC） LiveCodeBench release_v6 最新 35 题（中等 10、困难 25）

结论

- 正确率：DS-V4-Pro 32/35（91.4%）最高；Kimi K3.1 Pro、DS-V4.1-Flash 均 30/35（85.7%）。相差 2 题，35 题样本内不显著。中等题 Kimi、DS-V4-Pro 10/10，DS-V4.1-Flash 9/10；困难题（25 题）DS-V4-Pro 22、DS-V4.1-Flash 21、Kimi 20。
- 速度：每题延迟中位数 DS-V4.1-Flash 64 秒、Kimi 199 秒、DS-V4-Pro 285 秒；输出速度中位数 DS-V4.1-Flash 179、DS-V4-Pro 134、Kimi 65 token/秒。
- 费用：按 token 计：DS-V4.1-Flash $0.39、DS-V4-Pro $3.33、Kimi $8.57；每道通过题 $0.013 / $0.104 / $0.286。Kimi 实际扣费 $17.59，其中 $9.02 花在 7 个未返回结果的请求上。
- 选型：性价比 DS-V4.1-Flash（与 Kimi 同分，费用为 Kimi 的 1/22，速度最快）；最高正确率 DS-V4-Pro（每题输出 token 中位数为 Flash 的 3.2 倍）；Kimi K3.1 Pro 中等题全对，但最慢、单价最高，非流式长请求在余额不足时挂起 1 小时以上且照常扣费，须用流式 + 空闲超时调用。

1 模型

	Kimi K3.1 Pro	DeepSeek-V4.1-Flash	DeepSeek-V4-Pro
API 模型名	`kimi-k3.1-pro`	`deepseek-flash`	`deepseek-v4-pro`
最近更新	K3.1 系列首发	2026-10-17（1017 版）	2026-08-13（GA）
规模	3T 级，K3（2.8T）后训练	552B MoE，激活 8B 输入 / 16B 输出	未公布
权重	开放	开放，MIT	—
上下文 / 最大输出	1M / 默认 131,072	1M / 393,216	1M / 393,216
输入	文本、图像	文本、图像	文本
思考档位	恒开；low/high/max，默认 max	low/high/max，默认 high	low/high/max，默认 high
采样	固定 T=1.0、top_p=0.95	推荐 T=1.0	—
单价（美元/百万 token，输入 / 缓存 / 输出）	2 / 0.2 / 10，无峰谷	0.3 / 0.006 / 1.2，谷时半价	1.32 / 0.044 / 3.96，谷时半价

1.1 Kimi K3.1 Pro

- 变更：在 K3 上大幅增加后训练算力，覆盖数百个领域联合 RL；重做 RL 框架、长上下文推理、沙箱、rollout 调度。

- 官方提升方向：编程、3D 建模（直接写 Blender / CAD 脚本）、金融研究（内部 Financial Research 比 K3 高 11.6 分）、智能体。
- 安全：中期训练与 RL 数据剔除网络安全内容；xdev-bench-hard pass@3 81.0%（不剔除 90.5%）。
- 高速版 `kimi-k3.1-pro-highspeed`：速度 2–3 倍，价格 2 倍。K2 系列 2026 年底下线。
- 使用限制：充值 ≥1 美元解锁；累计充值决定并发 / TPM；temperature、top_p、n、penalty 不可传。
- 官方文档中的编程基准分数为占位符（"[xx.x%]"），无可引用数据。

1.2 DeepSeek-V4.1-Flash

- 2026-09-10 发布：20 层因果编码器 + 20 层解码器；MoE 1 共享 + 384 路由专家，每 token 激活 6 个；KV 缓存 890 字节/token，HBM 为上一代 1/4、SSD 为 1/8；原生视觉；降价；V4-Flash 下线。
- 2026-10-17 更新为 1017 版（新 / 旧）：Terminal-Bench 4.0 42.3 / 31.2，DeepSWE v1.1 77.0 / 74.2，ProgramBench 29.1 / 20.3，NL2Repo 68.2 / 65.4，HLE 42.6 / 36.8；输出更短、耗时更少；价格与调用方式不变。
- Codeforces 3471（max 档；同表 V4-Pro 3348）。输出单价为 V4-Pro 的 30%、Kimi K3.1 Pro 的 12%。

1.3 DeepSeek-V4-Pro

- 2026-04-24 首发；2026-08-13 GA：HLE 42.7 / 60.0（无 / 有工具），Terminal-Bench 2.1 87.9，DeepSWE 62.7，NL2Repo 61.5，Toolathlon-Verified 74.1；引入 low/high/max 三档；2026-08-16 起峰谷定价。
- V4.1-Flash 新闻稿称 9 月 14 日起该模型名改由 V4.1-Flash 承接，更新日志称继续提供、计费不变。本次 API 返回模型名 `deepseek-v4-pro`，按 V4-Pro 单价扣费（见 4.3）。
- 仅文本输入；单价为 V4.1-Flash 的 3.3 倍；DeepSeek 自报多数基准低于 V4.1-Flash。

2 评测方法

项目	设置
评测集	LiveCodeBench release_v6（ICLR 2025），官方提示词、官方判题，隐藏用例全过才算通过
指标	pass@1，每题 1 次
调用	官方 API；`BAI-AI-Lab/codingBench`，`cb livecodebench`
思考档位	各模型默认（Kimi max，DeepSeek high）
采样	DeepSeek：temperature 0.2（LCB 官方）；Kimi：固定 1.0
输出上限	DeepSeek 262,144；Kimi 131,072（默认）；全部回答正常结束（finish_reason=stop），无截断
并发	V4.1-Flash 16，V4-Pro 8；Kimi 前 32 题 4 路非流式，后 3 题 1 路流式（5 分钟无 token 判超时）；延迟含服务端排队
计量	每次调用记录起止时间与服务端返回的 token（含思考）
费用	官方单价 × token，DeepSeek 按调用时段区分峰谷；用账户余额变化核对

3 评测题目

3.1 分布

release_v6 最新 100 题中，按难度各取最新：中等 10、困难 25；发布于 2025-03-15 至 2025-04-06。

难度	AtCoder	LeetCode	合计
中等	7	3	10
困难	19	6	25
合计	26	9	35

来源	题数	形式
AtCoder ABC 397–400	17	完整程序，标准输入输出
AtCoder ARC 195–196	9	完整程序，标准输入输出
LeetCode 周赛 / 双周赛	9	补全给定 Python 函数

3.2 示例

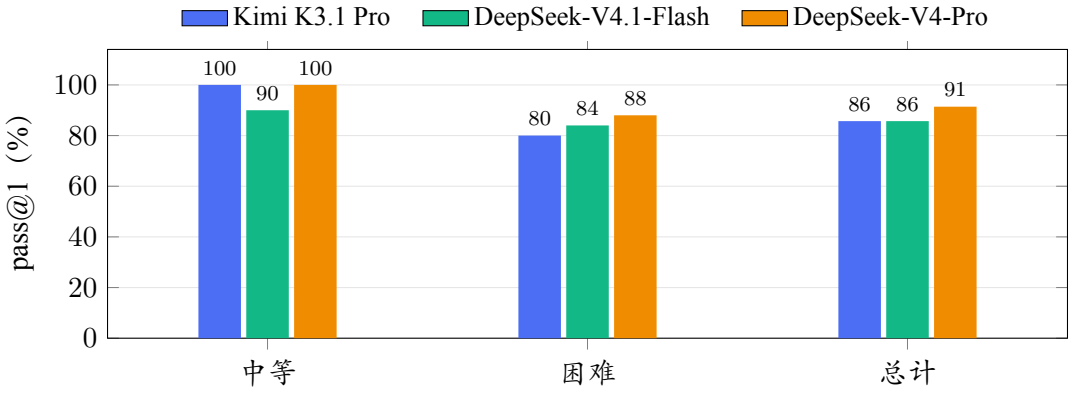
题目	内容
ABC 400 C “2^a b^2” 中等， 2025-04-05	**题意**：$X = 2^a b^2$（$a, b \geq 1$）为好数；给定 $N \leq 10^{18}$，求 $[1, N]$ 内好数个数。$N = 20$ 时为 5（2, 4, 8, 16, 18）。 **考点**：好数恰为 $2m^2$ 或 $4m^2$ 两类且互不重叠，答案 $\lfloor\sqrt{N/2}\rfloor + \lfloor\sqrt{N/4}\rfloor$；须用整数开方，浮点 `sqrt` 在 10^{18} 附近出错。 **结果**：Kimi ✓，2.3k token，35 秒；DS-Flash ✓，1.3k token，7 秒；DS-Pro ✓，3.4k token，25 秒
ARC 195 D “Swap and Erase” 困难， 2025-03-23	**题意**：可交换相邻元素，或删除开头一段全部相等的前缀；求删空序列的最少操作数。$T \leq 10^5$，$\sum N \leq 2 \times 10^5$。 **考点**：交换与删除的组合优化，须近线性时间。样例：$(1, 1, 2, 1, 2)$ 为 3（1 次交换 + 2 次删除），$(4, 2, 1, 3)$ 为 4（不交换）。 **结果**：Kimi ✓，86.5k token，1089 秒；DS-Flash ✓，81.0k token，475 秒；DS-Pro ✓，110.3k token，815 秒
LeetCode 3801 “Count Beautiful Numbers” 困难， 2025-03-15	**题意**：各位数字之积能被各位数字之和整除的正整数为美丽数；给定 $1 \leq l \leq r < 10^9$，求区间内个数。补全 `beautifulNumbers(self, l, r)`。 **考点**：数位 DP；含 0 时积为 0 必满足，否则积为 $2^a 3^b 5^c 7^d$，状态有限；暴力枚举超时。 **结果**：Kimi ✓，6.4k token，99 秒；DS-Flash ✓，3.8k token，22 秒；DS-Pro ✓，66.3k token，474 秒

4 评测结果

4.1 总表

指标	Kimi K3.1 Pro	DS-V4.1-Flash	DS-V4-Pro
通过（总计 35）	30（85.7%）	30（85.7%）	**32（91.4%）**
中等（10）	**10**	9	**10**
困难（25）	20	21	**22**
AtCoder（26）	21	21	**23**
LeetCode（9）	**9**	**9**	**9**
实际作答题数	35	35	35
有效运行时间（分钟）	143	**9**	49
每题延迟中位数（秒）	199	**64**	285
每题延迟 P90（秒）	1089	**327**	834
每题延迟最长（秒）	1888	**475**	1378
输出速度中位数（token/秒）	65	**179**	134
输出 token 合计	852k	644k	1.67M
其中思考 token 占比	98%	97%	99%
每题输出 token 中位数	14k	**12k**	38k
输入 token 合计（缓存命中）	24k（0k）	22k（16k）	24k（0k）
费用（美元，按 token 计）	$8.57	**$0.39**	$3.33
每道通过题的费用（美元）	$0.286	**$0.013**	$0.104
API 出错次数	31	0	13

粗体为该行最优。1 题 = 2.9 个百分点。有效运行时间 = 成功请求覆盖的时长（不含因余额不足暂停的时间）。API 出错：DS-V4-Pro 13 次为余额不足（402）；Kimi 30 次为挂起请求被切断后的连接错误，1 次为余额不足（429）。



4.2 按难度

难度	模型	通过	延迟中位数（秒）	平均输出 token	最多输出 token
中等	Kimi K3.1 Pro	10/10	34	7k	27k
中等	DeepSeek-V4.1-Flash	9/10	8	10k	49k
中等	DeepSeek-V4-Pro	10/10	28	16k	64k
困难	Kimi K3.1 Pro	20/25	280	31k	119k
困难	DeepSeek-V4.1-Flash	21/25	79	22k	81k
困难	DeepSeek-V4-Pro	22/25	388	61k	174k

4.3 费用核对

- DS-V4.1-Flash：账户余额 ¥11.32 → ¥9.37，实扣 ¥1.95；按美元价目折算 $0.39（人民币账户按人民币价目扣费）。
- DS-V4-Pro：按 token 计 $3.33（全部在谷时）。运行中两次充值金额未记录，无法用余额核对。13 次调用因余额不足立即返回 402、不生成内容，充值后补跑。
- Kimi K3.1 Pro：三次充值共 $17.50，最终余额 −$0.09，实扣 $17.59。成功返回的 35 次调用按 token 计 $8.57。差额 $9.02（按余额变化推算）对应 7 个未返回结果的请求：4 个在余额耗尽后挂起 1–1.5 小时，3 个被手动中断。

4.4 分析

- 共同结果:28 题三个模型都通过;`abc397_d`、`arc195_c` 三个模型都失败。只有 Kimi 通过:`arc196_b`;只有 DS-V4-Pro 通过：`abc398_f`。
- Kimi 失败的 5 题：
  - `abc397_d`、`arc195_c`：答案错误。
  - `abc398_g`：运行错误（IndexError）；思考 11.9 万 token、31 分钟，正常结束。
  - `abc398_f`：运行错误，原因是评测框架限制（见下）。
  - `abc399_e`：返回与题目无关的拒答（内容是一部电影的营销手法），输入 610 token 正常，判为无代码；疑似服务端错误，未重跑。
- DS-V4.1-Flash 失败：`abc399_c`、`abc397_d`、`arc195_c` 答案错误；`abc398_f`、`arc196_b` 运行错误。DS-V4-Pro 失败：`abc397_d`、`arc195_c` 答案错误；`arc196_b` 运行错误。
- 评测框架限制：LCB 判题用 StringIO 捕获标准输出，不支持 `sys.stdout.buffer`。35 题中只有 `abc398_f` 上的 DS-V4.1-Flash 和 Kimi 用了它，均报 AttributeError；DS-V4-Pro 用 `print`，通过。读入用 `sys.stdin.buffer` 不受影响。
- 推理量：每题输出 token 中位数 DS-V4.1-Flash 12k、Kimi 14k、DS-V4-Pro 38k；困难题平均 22k / 31k / 61k。DS-V4-Pro 用 Flash 2.8 倍的困难题 token，多做对 1 道困难题。
- 调用稳定性：DeepSeek 余额不足时立即返回 402，补跑即可，已答结果不丢。Kimi 非流式请求在余额耗尽后挂起 1–1.5 小时，既不返回也不报错；改为流式 + 5 分钟空闲超时后，最后 3 题单路完成（每题 20–31 分钟）。

4.5 逐题结果

每个模型：结果 / 输出 token（含思考）/ 延迟（秒）。

题号	题目	难度	Kimi K3.1 Pro			DS-V4.1-Flash			DS-V4-Pro		
abc398_b	Full House 3	中	✓	0.9k	15	✓	0.3k	3	✓	1.0k	7
abc398_c	Uniqueness	中	✓	0.4k	5	✓	0.4k	3	✓	0.4k	4
arc195_a	Twice Subsequence	中	✓	2.2k	34	✓	2.9k	16	✓	18.4k	144
abc399_c	Make it Forest	中	✓	0.5k	8	✗答案错误	0.5k	3	✓	0.4k	4
abc399_d	Switch Seats	中	✓	25.4k	409	✓	26.8k	149	✓	38.2k	282
abc400_c	2^a b^2	中	✓	2.3k	35	✓	1.3k	7	✓	3.4k	25
abc400_d	Takahashi the Wall Breaker	中	✓	26.7k	416	✓	49.0k	290	✓	63.9k	544
3809	properties-graph	中	✓	0.6k	10	✓	0.4k	3	✓	1.1k	8
3805	maximize-active-section-w…	中	✓	7.5k	94	✓	13.4k	75	✓	27.9k	208
3793	longest-palindrome-after-…	中	✓	2.7k	44	✓	1.5k	9	✓	4.0k	30
abc397_d	Cubes	难	✗答案错误	3.3k	49	✗答案错误	5.0k	25	✗答案错误	26.4k	179
abc397_e	Path Decomposition of a T…	难	✓	26.7k	451	✓	15.6k	95	✓	42.5k	332
abc397_f	Variety Split Hard	难	✓	64.0k	944	✓	21.4k	107	✓	55.9k	403
abc397_g	Maximize Distance	难	✓	33.1k	423	✓	14.5k	76	✓	55.8k	423
abc398_d	Bonfire	难	✓	4.4k	74	✓	2.8k	16	✓	10.8k	80
abc398_f	ABCBA	难	✗运行/编译错误	6.4k	97	✗运行/编译错误	1.7k	9	✓	38.2k	285
abc398_g	Not Only Tree Game	难	✗运行/编译错误	118.7k	1888	✓	63.4k	327	✓	174.0k	1378
arc195_b	Uniform Sum	难	✓	54.6k	924	✓	16.7k	96	✓	55.7k	454
arc195_c	Hamiltonian Pieces	难	✗答案错误	20.9k	322	✗答案错误	22.4k	120	✗答案错误	64.1k	453
arc195_d	Swap and Erase	难	✓	86.5k	1089	✓	81.0k	475	✓	110.3k	815
arc195_e	Random Tree Distance	难	✓	11.7k	176	✓	11.6k	64	✓	37.9k	256
abc399_e	Replace	难	✗无代码	2.8k	51	✓	26.3k	164	✓	55.0k	463
abc399_f	Range Power Sum	难	✓	2.5k	38	✓	2.5k	12	✓	6.6k	51
abc400_e	Ringo's Favorite Numbers 3	难	✓	3.1k	47	✓	3.1k	16	✓	10.2k	79
abc400_g	Patisserie ABC 3	难	✓	43.4k	735	✓	55.0k	334	✓	112.7k	941
arc196_a	Adjacent Delete	难	✓	33.4k	536	✓	18.3k	98	✓	48.3k	351
arc196_b	Torus Loop	难	✓	16.9k	280	✗运行/编译错误	22.7k	121	✗运行/编译错误	67.9k	496
arc196_c	Strongly Connected	难	✓	105.4k	1730	✓	76.8k	439	✓	164.2k	1221
arc196_d	Roadway	难	✓	68.1k	1230	✓	43.0k	248	✓	110.4k	834
3784	longest-common-prefix-of-…	难	✓	20.5k	296	✓	8.9k	50	✓	49.4k	368
3801	count-beautiful-numbers	难	✓	6.4k	99	✓	3.8k	22	✓	66.3k	474
3744	minimum-operations-to-mak…	难	✓	14.1k	220	✓	5.9k	33	✓	34.9k	250
3765	minimum-cost-to-divide-ar…	难	✓	6.5k	80	✓	3.5k	19	✓	35.1k	259
3717	minimum-operations-to-mak…	难	✓	14.1k	214	✓	7.6k	40	✓	30.1k	215
3777	maximum-product-of-subseq…	难	✓	15.2k	199	✓	13.9k	79	✓	50.8k	388

5 局限

- 35 题、每题 1 次：30/35 的 95% 置信区间约 70%–95%，相差 1–2 题不显著。
- 采样温度不同：DeepSeek 0.2，Kimi 固定 1.0。
- 延迟受并发和服务端负载影响。
- 题目早于三个模型发布，不排除训练数据污染。
- LCB 官方判题不支持 `sys.stdout.buffer`，影响 `abc398_f`（未修改官方实现）。

- Kimi 的 abc399_e 回答与题目无关，按原样计为失败；余额不足，未重跑。

来源

- Kimi：https://platform.kimi.ai/docs/guide/kimi-k3-1-pro-quickstart，https://platform.kimi.ai/docs/models，https://platform.kimi.ai/docs/pricing/chat
- DeepSeek：https://api-docs.deepseek.com/updates/，https://www.deepseek.com/en/news/deepseek-v4-1-flash/，https://huggingface.co/deepseek-ai/DeepSeek-V4.1-Flash，https://api-docs.deepseek.com/quick_start/pricing
- 上下文、最大输出、默认档位：两家 API /v1/models（2026-10-23）
- LiveCodeBench：https://livecodebench.github.io