LiveCodeBench 代码能力评测

Kimi K3.1 Pro / DeepSeek-V4.1-Flash / DeepSeek-V4-Pro

2026-10-23（UTC） LiveCodeBench release_v6 最新 35 题（中等 10、困难 25）

结论

- 正确率：DS-V4.1-Flash 35/35、DS-V4-Pro 35/35、Kimi K3.1 Pro 34/35（只错 `abc398_g`）。
- 速度：每题延迟中位数：DS-V4.1-Flash 64 秒、Kimi 199 秒、DS-V4-Pro 285 秒。输出速度中位数：DS-V4.1-Flash 179、DS-V4-Pro 134、Kimi 65 token/秒。
- 费用：按 token 计：DS-V4.1-Flash $0.39、DS-V4-Pro $3.33、Kimi $8.57。每道通过题：$0.011 / $0.095 / $0.252。
- 代码：在 13 道能区分性能的题上，Kimi 最快（相对最快倍数几何平均 1.29），DS-V4.1-Flash 2.00，DS-V4-Pro 2.74；DS-V4-Pro 6 题最快但另有 6 题慢 2 倍以上。按 arXiv:2610.19167 的静态质量口径，Kimi 代码最短、Pylint 问题最少、可维护性指数最高（见 5.4）。
- 选型：只看通过率和成本，DS-V4.1-Flash 最优（满分，费用为 Pro 的 12%、Kimi 的 5%，延迟最低）；看代码运行效率，Kimi K3.1 Pro 最好，但输出最慢、费用最高；DS-V4-Pro 满分，但 token 最多、代码效率波动最大。

1 模型

	Kimi K3.1 Pro	DeepSeek-V4.1-Flash	DeepSeek-V4-Pro
API 模型名	`kimi-k3.1-pro`	`deepseek-flash`	`deepseek-v4-pro`
最近更新	K3.1 系列首发	2026-10-17（1017 版）	2026-08-13（GA）
规模	3T 级，K3（2.8T）后训练	552B MoE，激活 8B 输入 / 16B 输出	未公布
权重	开放	开放，MIT	—
上下文 / 最大输出	1M / 默认 131,072	1M / 393,216	1M / 393,216
输入	文本、图像	文本、图像	文本
思考档位	恒开；low/high/max，默认 max	low/high/max，默认 high	low/high/max，默认 high
采样	固定 T=1.0、top_p=0.95	推荐 T=1.0	—
单价（美元/百万 token，输入 / 缓存 / 输出）	2 / 0.2 / 10，无峰谷	0.3 / 0.006 / 1.2，谷时半价	1.32 / 0.044 / 3.96，谷时半价

1.1 Kimi K3.1 Pro

- 变更：在 K3 上大幅增加后训练算力，覆盖数百个领域联合 RL；重做 RL 框架、长上下文推理、沙箱、rollout 调度。
- 官方提升方向：编程、3D 建模（直接写 Blender / CAD 脚本）、金融研究（内部 Financial Research 比 K3 高 11.6 分）、智能体。
- 安全：中期训练与 RL 数据剔除网络安全内容；xdev-bench-hard pass@3 81.0%（不剔除 90.5%）。
- 高速版 `kimi-k3.1-pro-highspeed`：速度 2–3 倍，价格 2 倍。K2 系列 2026 年底下线。
- 使用限制：充值 ≥1 美元解锁；累计充值决定并发 / TPM；temperature、top_p、n、penalty 不可传。
- 官方文档中的编程基准分数为占位符（"[xx.x%]"），无可引用数据。

1.2 DeepSeek-V4.1-Flash

- 2026-09-10 发布：20 层因果编码器 + 20 层解码器；MoE 1 共享 + 384 路由专家，每 token 激活 6 个；KV 缓存 890 字节/token，HBM 为上一代 1/4、SSD 为 1/8；原生视觉；降价；V4-Flash 下线。
- 2026-10-17 更新为 1017 版（新 / 旧）：Terminal-Bench 4.0 42.3 / 31.2，DeepSWE v1.1 77.0 / 74.2，ProgramBench 29.1 / 20.3，NL2Repo 68.2 / 65.4，HLE 42.6 / 36.8；输出更短、耗时更少；价格与调用方式不变。
- Codeforces 3471（max 档；同表 V4-Pro 3348）。输出单价为 V4-Pro 的 30%、Kimi K3.1 Pro 的 12%。

1.3 DeepSeek-V4-Pro

- 2026-04-24 首发；2026-08-13 GA：HLE 42.7 / 60.0（无 / 有工具），Terminal-Bench 2.1 87.9，DeepSWE 62.7，NL2Repo 61.5，Toolathlon-Verified 74.1；引入 low/high/max 三档；2026-08-16 起峰谷定价。
- V4.1-Flash 新闻稿称 9 月 14 日起该模型名改由 V4.1-Flash 承接，更新日志称继续提供、计费不变。本次 API 返回模型名 `deepseek-v4-pro`，按 V4-Pro 单价扣费。
- 仅文本输入；单价为 V4.1-Flash 的 3.3 倍；DeepSeek 自报多数基准低于 V4.1-Flash。

2 评测方法

项目	设置
评测集	LiveCodeBench release_v6（ICLR 2025），官方提示词与官方测试数据，全部测试通过才算通过
指标	pass@1，每题 1 次
调用	官方 API；`BAI-AI-Lab/codingBench`，`cb livecodebench`
思考档位	各模型默认（Kimi max，DeepSeek high）
采样	DeepSeek：temperature 0.2（LCB 官方）；Kimi：固定 1.0
输出上限	DeepSeek 262,144；Kimi 131,072（默认）；全部回答正常结束（finish_reason=stop），无截断
并发	V4.1-Flash 16，V4-Pro 8，Kimi 1–4；延迟含服务端排队
计量	每次调用记录起止时间与服务端返回的 token（含思考）
费用	官方单价 × token，DeepSeek 按调用时段区分峰谷
判题	AtCoder：每份答案作为独立 Python 进程，用真实标准输入输出运行全部官方测试（每个测试 6 秒），逐 token 比对；`abc397_d`、`arc195_c` 用按题意编写的校验器（前者第 41 个测试的标准答案不满足题意，后者允许任意合法构造）。LeetCode：LCB 的函数调用判题

3 评测题目

3.1 分布

release_v6 最新 100 题中，按难度各取最新：中等 10、困难 25；发布于 2025-03-15 至 2025-04-06。

难度	AtCoder	LeetCode	合计
中等	7	3	10
困难	19	6	25
合计	26	9	35

来源	题数	形式
AtCoder ABC 397–400	17	完整程序，标准输入输出
AtCoder ARC 195–196	9	完整程序，标准输入输出
LeetCode 周赛 / 双周赛	9	补全给定 Python 函数

3.2 示例

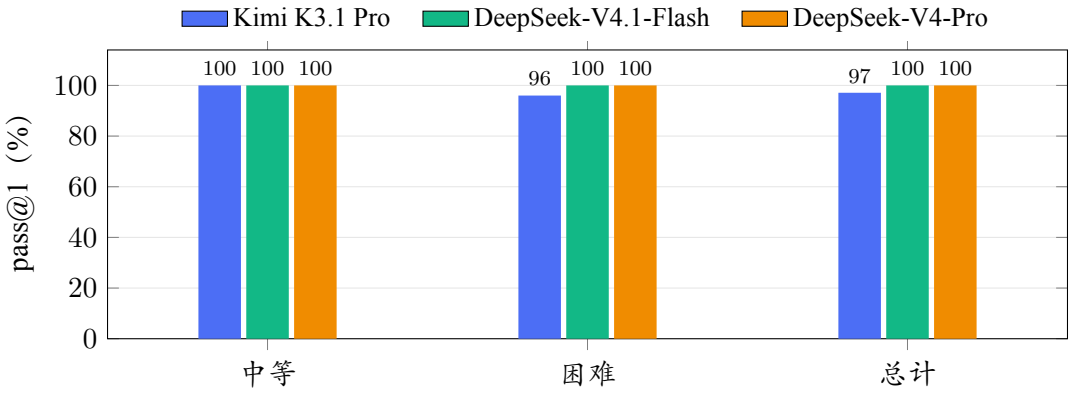
题目	内容
ABC 400 C “2^a b^2” 中等， 2025-04-05	**题意**：$X = 2^a b^2$（$a, b \geq 1$）为好数；给定 $N \leq 10^{18}$，求 $[1, N]$ 内好数个数。$N = 20$ 时为 5（2, 4, 8, 16, 18）。 **考点**：好数恰为 $2m^2$ 或 $4m^2$ 两类且互不重叠，答案 $\lfloor\sqrt{N/2}\rfloor + \lfloor\sqrt{N/4}\rfloor$；须用整数开方，浮点 `sqrt` 在 10^{18} 附近出错。 **结果**：Kimi ✓，2.3k token，35 秒；DS-Flash ✓，1.3k token，7 秒；DS-Pro ✓，3.4k token，25 秒
ARC 195 D “Swap and Erase” 困难， 2025-03-23	**题意**：可交换相邻元素，或删除开头一段全部相等的前缀；求删空序列的最少操作数。$T \leq 10^5$，$\sum N \leq 2 \times 10^5$。 **考点**：交换与删除的组合优化，须近线性时间。样例：$(1, 1, 2, 1, 2)$ 为 3（1 次交换 + 2 次删除），$(4, 2, 1, 3)$ 为 4（不交换）。 **结果**：Kimi ✓，86.5k token，1089 秒；DS-Flash ✓，81.0k token，475 秒；DS-Pro ✓，110.3k token，815 秒
LeetCode 3801 “Count Beautiful Numbers” 困难， 2025-03-15	**题意**：各位数字之积能被各位数字之和整除的正整数为美丽数；给定 $1 \leq l \leq r < 10^9$，求区间内个数。补全 `beautifulNumbers(self, l, r)`。 **考点**：数位 DP；含 0 时积为 0 必满足，否则积为 $2^a 3^b 5^c 7^d$，状态有限；暴力枚举超时。 **结果**：Kimi ✓，6.4k token，99 秒；DS-Flash ✓，3.8k token，22 秒；DS-Pro ✓，66.3k token，474 秒

4 评测结果

4.1 总表

指标	Kimi K3.1 Pro	DS-V4.1-Flash	DS-V4-Pro
通过（总计 35）↑	34（97.1%）	**35（100.0%）**	**35（100.0%）**
中等（10）↑	**10**	**10**	**10**
困难（25）↑	24	**25**	**25**
AtCoder（26）↑	25	**26**	**26**
LeetCode（9）↑	**9**	**9**	**9**
有效运行时间（分钟）↓	143	**9**	49
每题延迟中位数（秒）↓	199	**64**	285
每题延迟 P90（秒）↓	1089	**327**	834
每题延迟最长（秒）↓	1888	**475**	1378
输出速度中位数（token/秒）↑	65	**179**	134
输出 token 合计↓	852k	**644k**	1.67M
其中思考 token 占比	98%	97%	99%
每题输出 token 中位数↓	14k	**12k**	38k
输入 token 合计（缓存命中）	24k（0k）	22k（16k）	24k（0k）
费用（美元，按 token 计）↓	$8.57	**$0.39**	$3.33
每道通过题的费用（美元）↓	$0.252	**$0.011**	$0.095

↑越大越好，↓越小越好，没有箭头的行只作描述；粗体为该行最优。1 题 = 2.9 个百分点。有效运行时间 = 成功请求覆盖的时长。



4.2 按难度

难度	模型	通过↑	延迟中位数（秒）↓	平均输出 token↓	最多输出 token↓
中等	Kimi K3.1 Pro	10/10	34	7k	27k
中等	DeepSeek-V4.1-Flash	10/10	8	10k	49k
中等	DeepSeek-V4-Pro	10/10	28	16k	64k
困难	Kimi K3.1 Pro	24/25	280	31k	119k
困难	DeepSeek-V4.1-Flash	25/25	79	22k	81k
困难	DeepSeek-V4-Pro	25/25	388	61k	174k

4.3 分析

- 唯一的错误：Kimi `abc398_g`（博弈题），思考 11.9 万 token、耗时 31 分钟后，在 4/43 个测试上答案错误。这题 DS-V4.1-Flash 用 6.3 万 token、DS-V4-Pro 用 17.4 万 token 都做对了。
- 推理量：每题输出 token 中位数 DS-V4.1-Flash 12k、Kimi 14k、DS-V4-Pro 38k；困难题平均分别为 22k、31k、61k。DS-V4-Pro 多用的 token 没有换来更多通过题。

4.4 逐题结果

每个模型：结果 / 输出 token（含思考，越小越好）/ 延迟（秒，越小越好）。† 评测中 API 返回的内容与题目无关，人工另行调用验证正确，按通过计。

题号	题目	难度	Kimi K3.1 Pro		DS-V4.1-Flash		DS-V4-Pro	
`abc398_b`	Full House 3	中	✓ 0.9k	15	✓ 0.3k	3	✓ 1.0k	7
`abc398_c`	Uniqueness	中	✓ 0.4k	5	✓ 0.4k	3	✓ 0.4k	4
`arc195_a`	Twice Subsequence	中	✓ 2.2k	34	✓ 2.9k	16	✓ 18.4k	144
`abc399_c`	Make it Forest	中	✓ 0.5k	8	✓ 0.5k	3	✓ 0.4k	4
`abc399_d`	Switch Seats	中	✓ 25.4k	409	✓ 26.8k	149	✓ 38.2k	282
`abc400_c`	2^a b^2	中	✓ 2.3k	35	✓ 1.3k	7	✓ 3.4k	25
`abc400_d`	Takahashi the Wall Breaker	中	✓ 26.7k	416	✓ 49.0k	290	✓ 63.9k	544
`3809`	properties-graph	中	✓ 0.6k	10	✓ 0.4k	3	✓ 1.1k	8
`3805`	maximize-active-section-w…	中	✓ 7.5k	94	✓ 13.4k	75	✓ 27.9k	208
`3793`	longest-palindrome-after-…	中	✓ 2.7k	44	✓ 1.5k	9	✓ 4.0k	30
`abc397_d`	Cubes	难	✓ 3.3k	49	✓ 5.0k	25	✓ 26.4k	179
`abc397_e`	Path Decomposition of a T…	难	✓ 26.7k	451	✓ 15.6k	95	✓ 42.5k	332
`abc397_f`	Variety Split Hard	难	✓ 64.0k	944	✓ 21.4k	107	✓ 55.9k	403
`abc397_g`	Maximize Distance	难	✓ 33.1k	423	✓ 14.5k	76	✓ 55.8k	423
`abc398_d`	Bonfire	难	✓ 4.4k	74	✓ 2.8k	16	✓ 10.8k	80
`abc398_f`	ABCBA	难	✓ 6.4k	97	✓ 1.7k	9	✓ 38.2k	285
`abc398_g`	Not Only Tree Game	难	✗答案错误 118.7k	1888	✓ 63.4k	327	✓ 174.0k	1378
`arc195_b`	Uniform Sum	难	✓ 54.6k	924	✓ 16.7k	96	✓ 55.7k	454
`arc195_c`	Hamiltonian Pieces	难	✓ 20.9k	322	✓ 22.4k	120	✓ 64.1k	453
`arc195_d`	Swap and Erase	难	✓ 86.5k	1089	✓ 81.0k	475	✓ 110.3k	815
`arc195_e`	Random Tree Distance	难	✓ 11.7k	176	✓ 11.6k	64	✓ 37.9k	256
`abc399_e`	Replace	难	✓† 2.8k	51	✓ 26.3k	164	✓ 55.0k	463
`abc399_f`	Range Power Sum	难	✓ 2.5k	38	✓ 2.5k	12	✓ 6.6k	51
`abc400_e`	Ringo's Favorite Numbers 3	难	✓ 3.1k	47	✓ 3.1k	16	✓ 10.2k	79

题号	题目	难度	Kimi K3.1 Pro		DS-V4.1-Flash		DS-V4-Pro	
abc400_g	Patisserie ABC 3	难 ✓	43.4k	735 ✓	55.0k	334 ✓	112.7k	941
arc196_a	Adjacent Delete	难 ✓	33.4k	536 ✓	18.3k	98 ✓	48.3k	351
arc196_b	Torus Loop	难 ✓	16.9k	280 ✓	22.7k	121 ✓	67.9k	496
arc196_c	Strongly Connected	难 ✓	105.4k	1730 ✓	76.8k	439 ✓	164.2k	1221
arc196_d	Roadway	难 ✓	68.1k	1230 ✓	43.0k	248 ✓	110.4k	834
3784	longest-common-prefix-of-…	难 ✓	20.5k	296 ✓	8.9k	50 ✓	49.4k	368
3801	count-beautiful-numbers	难 ✓	6.4k	99 ✓	3.8k	22 ✓	66.3k	474
3744	minimum-operations-to-mak…	难 ✓	14.1k	220 ✓	5.9k	33 ✓	34.9k	250
3765	minimum-cost-to-divide-ar…	难 ✓	6.5k	80 ✓	3.5k	19 ✓	35.1k	259
3717	minimum-operations-to-mak…	难 ✓	14.1k	214 ✓	7.6k	40 ✓	30.1k	215
3777	maximum-product-of-subseq…	难 ✓	15.2k	199 ✓	13.9k	79 ✓	50.8k	388

5 代码性能与静态指标

5.1 测量方法

项目	设置
对象	通过的答案（Kimi 33 份，不含 abc398_g、abc399_e；DeepSeek 各 35 份）
运行	每次运行都是一个全新的 Python 3.11 进程（LCB 环境），绑定到单个 CPU 核；共 11,124 次，输出全部正确
计时	AtCoder：进程 CPU 时间（rusage）扣除启动基线 25.7 ms；LeetCode：只计 Solution 方法调用的 CPU 时间
内存	进程峰值常驻内存（ru_maxrss）；空程序为 12.1 MB
重复	每个测试 3 次、三个模型轮流先跑，取中位数；同一测试 3 次的离散度中位数 2.0%，P90 6.4%
可比题	最慢答案扣除启动后仍 ≥ 0.1 秒的题，共 13 题；其余 22 题官方测试太小，耗时主要是启动开销，不比较

5.2 逐题性能

题号	难度	类型	最大输入 KB	Kimi K3.1 Pro		DS-V4.1-Flash		DS-V4-Pro	
				CPU 秒↓	MB↓	CPU 秒↓	MB↓	CPU 秒↓	MB↓
abc399_c	中	AC	2517	0.23	50	0.26	22	**0.22**	44
abc399_d	中	AC	1758	0.15	38	0.28 (2.3×)	48	**0.12**	48
3717	难	LC	830	**1.00**	37	1.40	41	1.21	37
3744	难	LC	2137	0.27 (5.0×)	32	0.67 (12.5×)	32	**0.05**	32
3765	难	LC	9	**0.14**	16	0.14	16	1.24 (9.1×)	16
3784	难	LC	391	0.11 (2.2×)	22	0.06	28	**0.05**	22
3801	难	LC	0	**0.11**	26	0.11	26	0.93 (8.3×)	18
abc397_d	难	AC	0	0.14	12	0.14	12	**0.11**	12
abc397_g	难	AC	0	**0.01**	14	0.02 (2.5×)	14	0.23 (36.1×)	14
abc400_e	难	AC	0	0.43	36	0.39	32	**0.26**	24
abc400_g	难	AC	2773	**0.16**	32	0.27	40	1.45 (9.3×)	40
arc195_b	难	AC	37	**0.15**	14	1.30 (8.5×)	91	0.96 (6.3×)	119
arc196_d	难	AC	80	**0.06**	16	0.13 (2.1×)	16	0.15 (2.5×)	18

↓越小越好。CPU 秒为最慢一个测试的 CPU 时间（3 次取中位数，扣除启动）；粗体为该题最快；括号内为相对最快者的倍数（≥ 2 时标出）。MB 为该题各测试中的最大峰值内存。AC = AtCoder，LC = LeetCode。

5.3 汇总

模型	相对最快倍数↓（几何平均）	最快↑（题）	慢 ≥ 2 倍↓（题）	CPU 合计↓（秒）	峰值内存（MB）↓ 中位数	最大
Kimi	**1.29**	7	2	16.7	26	50
DS-Flash	2.00	0	5	29.7	28	91
DS-Pro	2.74	6	6	52.8	24	119

↑越大越好，↓越小越好。基于 13 道可比题（三个模型都通过）。CPU 合计为这些题所有测试的 CPU 时间之和。“最快”按严格最小值计；有 3 题第二名与最快相差不到 5%（噪声范围内）：3765、3801 上 Flash 比 Kimi 慢 3% 和 2%，abc399_c 上 Kimi 比 Pro 慢 3%。按并列计，Flash 的最快题数为 2。

- arc195_b（Flash 慢 8.5 倍，内存 91 MB）：Flash 枚举 A、B 所有不同取值的两两组合，复杂度 $O(U \cdot V)$，并把重复的和逐个展开存入列表；Kimi 先按通配数量选出必须参与配对的候选值，再用二分查找限定候选和，0.15 秒。
- abc400_g（Pro 慢 9.3 倍）：Pro 为每组数据建图跑最小费用流；Kimi 用“取最大值后只修正奇偶”的贪心，每类只保留前两个候选，$O(N \log N)$。
- 3765（Pro 慢 9.1 倍）：Pro 按子数组个数分层、每层做凸包优化，$O(n^2 \log n)$；Kimi 直接用 $O(n^2)$ 的后缀 DP。
- 3801（Pro 慢 8.3 倍）：Pro 对每个可能的数位和 S 单独建 [剩余位数][和][积 mod S] 计数表；Kimi 用以（位置，和，积）为状态的记忆化数位 DP。

- abc397_g：Pro 0.23 秒、Kimi 0.01 秒，倍数大但绝对值都很小。
- 全部可比题的最慢测试都在 1.5 秒以内，未接近 AtCoder 常见的 2 秒时限；但评测机器与 AtCoder 不同，不能据此判断能否在原平台通过。

5.4 静态代码质量

按 Huang 等（arXiv:2610.19167，ICECCS 2026）的口径：Pylint 3.3.5（默认配置）、Radon 6.0.1（命令行）、SonarQube 10.4 Community（本机部署，默认质量配置）；每份答案原样分析，不补 import；不合成总分。Kimi 的 abc399_e 没有代码，不计入；“全部答案”与“仅通过”只差 Kimi 的 abc398_g 一份。

			Pylint						SonarQube		
模型	难度	份数	Pylint 合计↓	C↓	R↓	W↓	E↓	得分↑	可维护性↓	可靠性↓	安全↓
全部答案											
Kimi	中等	10	3.90	3.50	0.40	0.00	0.00	7.87	0.60	0.00	0.00
	困难	24	7.83	4.62	1.62	1.54	0.04	8.37	0.96	0.00	0.00
	合计	34	**6.68**	**4.29**	**1.26**	1.09	0.03	**8.22**	**0.85**	**0.00**	**0.00**
DS-Flash	中等	10	7.10	6.20	0.80	0.10	0.00	7.45	0.70	0.00	0.00
	困难	25	10.44	7.04	2.84	0.56	0.00	8.16	1.56	0.00	0.00
	合计	35	9.49	6.80	2.26	**0.43**	**0.00**	7.96	1.31	**0.00**	**0.00**
DS-Pro	中等	10	6.10	5.40	0.60	0.10	0.00	7.39	0.70	0.00	0.00
	困难	25	15.24	10.44	2.92	1.88	0.00	7.81	3.12	0.00	0.00
	合计	35	12.63	9.00	2.26	1.37	**0.00**	7.69	2.43	**0.00**	**0.00**
仅通过的答案											
Kimi	中等	10	3.90	3.50	0.40	0.00	0.00	7.87	0.60	0.00	0.00
	困难	23	7.96	4.70	1.65	1.57	0.04	8.35	0.91	0.00	0.00
	合计	33	**6.73**	**4.33**	**1.27**	1.09	0.03	**8.20**	**0.82**	**0.00**	**0.00**
DS-Flash	中等	10	7.10	6.20	0.80	0.10	0.00	7.45	0.70	0.00	0.00
	困难	25	10.44	7.04	2.84	0.56	0.00	8.16	1.56	0.00	0.00
	合计	35	9.49	6.80	2.26	**0.43**	**0.00**	7.96	1.31	**0.00**	**0.00**
DS-Pro	中等	10	6.10	5.40	0.60	0.10	0.00	7.39	0.70	0.00	0.00
	困难	25	15.24	10.44	2.92	1.88	0.00	7.81	3.12	0.00	0.00
	合计	35	12.63	9.00	2.26	1.37	**0.00**	7.69	2.43	**0.00**	**0.00**

每份答案平均。↑越大越好，↓越小越好。C 规范、R 重构、W 警告、E 错误，均为问题条数；得分 0–10；SonarQube 为可维护性、可靠性、安全三类问题数。粗体为合计行中最优。每份答案都有一条“缺少末尾换行”(C0304)，来自答案提取，三个模型相同。Kimi 的 1 个 E 是 arc196_c 导入 numpy（分析环境未安装 numpy）。

模型	难度	份数	CC↓	MI↑	Func	LOC	LLOC	SLOC	CMT	BLN
全部答案										
Kimi	中等	10	8.5	65.3	1.2	33.6	24.8	24.8	1.7	7.2
	困难	24	17.7	59.8	2.2	82.2	59.1	60.8	5.5	16.2
	合计	34	**15.0**	**61.4**	1.9	67.9	49.0	50.2	4.4	13.5
DS-Flash	中等	10	11.8	56.4	1.2	42.6	32.7	32.0	0.9	9.7
	困难	25	18.6	50.1	1.5	93.6	71.3	71.0	3.6	19.9
	合计	35	16.7	51.9	1.4	79.0	60.3	59.8	2.8	17.0
DS-Pro	中等	10	12.2	56.2	1.3	37.0	30.9	30.3	0.5	6.2
	困难	25	21.3	54.2	2.0	101.4	80.5	80.0	5.3	17.1
	合计	35	18.7	54.8	1.8	83.0	66.3	65.8	3.9	14.0
仅通过的答案										
Kimi	中等	10	8.5	65.3	1.2	33.6	24.8	24.8	1.7	7.2
	困难	23	17.9	59.9	2.3	83.3	59.9	61.7	5.7	16.3
	合计	33	**15.0**	**61.5**	1.9	68.2	49.2	50.5	4.5	13.5
DS-Flash	中等	10	11.8	56.4	1.2	42.6	32.7	32.0	0.9	9.7
	困难	25	18.6	50.1	1.5	93.6	71.3	71.0	3.6	19.9
	合计	35	16.7	51.9	1.4	79.0	60.3	59.8	2.8	17.0
DS-Pro	中等	10	12.2	56.2	1.3	37.0	30.9	30.3	0.5	6.2
	困难	25	21.3	54.2	2.0	101.4	80.5	80.0	5.3	17.1
	合计	35	18.7	54.8	1.8	83.0	66.3	65.8	3.9	14.0

每份答案平均。↑越大越好，↓越小越好；没有箭头的列只描述规模，不分好坏。CC 为圈复杂度，`radon cc -j` 全部条目之和（类与它的方法各计一条）；难题本身需要更多分支，且代码越长 CC 越高，宜结合每 100 有效行的密度看。MI 为可维护性指数，0–100，20 以上为易维护；Func 为条目数；LOC、LLOC、SLOC、CMT、BLN 分别为总行、逻辑行、有效行、注释行、空行。

			Pylint					Radon		SonarQube		
模型	难度	份数	Pylint 合计↓	C↓	R↓	W↓	E↓	CC↓	Func	可维护性↓	可靠性↓	安全↓
Kimi	中等	10	15.73	14.11	1.61	0.00	0.00	34.27	4.84	2.42	0.00	0.00
	困难	23	12.90	7.61	2.68	2.54	0.07	28.96	3.66	1.48	0.00	0.00
	合计	33	**13.32**	**8.58**	**2.52**	2.16	0.06	29.75	3.84	**1.62**	**0.00**	**0.00**
DS-Flash	中等	10	22.19	19.38	2.50	0.31	0.00	36.88	3.75	2.19	0.00	0.00
	困难	25	14.71	9.92	4.00	0.79	0.00	26.21	2.14	2.20	0.00	0.00
	合计	35	15.85	11.37	3.77	**0.72**	**0.00**	**27.84**	2.39	2.20	**0.00**	**0.00**
DS-Pro	中等	10	20.13	17.82	1.98	0.33	0.00	40.26	4.29	2.31	0.00	0.00
	困难	25	19.04	13.04	3.65	2.35	0.00	26.64	2.45	3.90	0.00	0.00
	合计	35	19.18	13.67	3.43	2.08	**0.00**	28.43	2.69	3.69	**0.00**	**0.00**

仅通过的答案，每 100 有效行（SLOC）的数量：各题之和 ÷ SLOC 之和 × 100。↓越小越好；Func 只描述代码拆分方式，不分好坏。

- Pylint（Kimi / DS-Flash / DS-Pro，每份）：问题 6.73 / 9.49 / 12.63，得分 8.20 / 7.96 / 7.69。DS-Pro 最多，主要是命名不合规（C0103，共 25 / 110 / 174 条）。
- 警告（W）Kimi 每份 1.09，高于 DS-Flash 的 0.43，但集中在 2 份答案的循环内闭包（W0640 33 条）；DS-Pro 的 W0640 有 34 条，集中在 1 份。未使用的变量（W0612）：Kimi 0、DS-Flash 3、DS-Pro 8 条。
- Radon（每份）：Kimi 代码最短（SLOC 50.5 / 59.8 / 65.8）、可维护性指数最高（61.5 / 51.9 / 54.8）、圈复杂度最低（15.0 / 16.7 / 18.7）。
- 按每 100 SLOC：Pylint 问题 13.32 / 15.85 / 19.18，排序不变；但 Kimi 的圈复杂度密度（29.75 / 27.84 / 28.43）和函数密度（3.84 / 2.39 / 2.69）最高，即代码更短、分支和函数更密。
- SonarQube（每份）：可维护性问题 0.82 / 1.31 / 2.43，三个模型的可靠性和安全问题都是 0。主要是函数认知复杂度过高（S3776，共 18 / 21 / 22 条）和局部变量命名不合规（S117，0 / 8 / 33 条）；函数命名（S100，9 / 9 / 9 条）来自 LeetCode 规定的驼峰式方法名。

  补充（不属于上述口径）：

模型	嵌套深度中位数↓	嵌套深度最大↓	AtCoder 读入方式（题数）
Kimi	5	7	buffer.read 20、read 3、buffer.readline 1
DS-Flash	5	10	buffer.read 17、readline 4、buffer.readline 2、read 1
DS-Pro	4	11	buffer.read 14、read 6、readline 3、buffer.readline 1

基于 33 道三个模型都通过的题。嵌套深度为语法树中复合语句的最大嵌套层数，越小越好；读入方式只作描述。Kimi 采样温度 1.0、DeepSeek 0.2，风格差异部分来自采样。

6 局限

- 35 题、每题 1 次：相差 1–2 题不显著；两个 DeepSeek 模型均为满分，这批题已不足以区分二者。
- 采样温度不同：DeepSeek 0.2，Kimi 固定 1.0。
- 延迟受并发和服务端负载影响。
- 题目早于三个模型发布，不排除训练数据污染。
- 成绩依赖本评测的判题程序和校验器。
- Kimi `abc399_e` 按人工另行调用的结果计为通过，未在本评测流程中复现。

来源

- Kimi：`https://platform.kimi.ai/docs/guide/kimi-k3-1-pro-quickstart`，`https://platform.kimi.ai/docs/models`，`https://platform.kimi.ai/docs/pricing/chat`
- DeepSeek：`https://api-docs.deepseek.com/updates/`，`https://www.deepseek.com/en/news/deepseek-v4-1-flash/`，`https://huggingface.co/deepseek-ai/DeepSeek-V4.1-Flash`，`https://api-docs.deepseek.com/quick_start/pricing`
- 上下文、最大输出、默认档位：两家 API `/v1/models`（2026-10-23）
- LiveCodeBench：`https://livecodebench.github.io`