LiveCodeBench 代码能力评测

Kimi K3.1 Pro / DeepSeek-V4.1-Flash / DeepSeek-V4-Pro

2026-10-23（UTC） LiveCodeBench release_v6 最新 35 题（中等 10、困难 25）

结论

- 正确率：复核后 DS-V4.1-Flash 35/35、DS-V4-Pro 35/35、Kimi K3.1 Pro 34/35（只错 `abc398_g`）。LCB 原始判分为 30 / 32 / 30，共 12 个失败由评测问题造成，不是模型错误（见 4.2）。
- 速度：每题延迟中位数：DS-V4.1-Flash 64 秒、Kimi 199 秒、DS-V4-Pro 285 秒。输出速度中位数：DS-V4.1-Flash 179、DS-V4-Pro 134、Kimi 65 token/秒。
- 费用：按 token 计：DS-V4.1-Flash $0.39、DS-V4-Pro $3.33、Kimi $8.57。每道通过题：$0.011 / $0.095 / $0.252。Kimi 实际扣费 $17.59，其中 $9.02 花在 7 个未返回结果的请求上。
- 选型：DS-V4.1-Flash 与 DS-V4-Pro 同为满分，但费用只有 Pro 的 12%，每题输出 token 中位数约为 Pro 的 1/3，延迟为 Pro 的 1/4.5。Kimi K3.1 Pro 34/35，速度最慢、单价最高；非流式长请求在余额不足时会挂起 1 小时以上且照常扣费，必须用流式 + 空闲超时调用。

1 模型

	Kimi K3.1 Pro	DeepSeek-V4.1-Flash	DeepSeek-V4-Pro
API 模型名	`kimi-k3.1-pro`	`deepseek-flash`	`deepseek-v4-pro`
最近更新	K3.1 系列首发	2026-10-17（1017 版）	2026-08-13（GA）
规模	3T 级，K3（2.8T）后训练	552B MoE，激活 8B 输入 / 16B 输出	未公布
权重	开放	开放，MIT	—
上下文 / 最大输出	1M / 默认 131,072	1M / 393,216	1M / 393,216
输入	文本、图像	文本、图像	文本
思考档位	恒开；low/high/max，默认 max	low/high/max，默认 high	low/high/max，默认 high
采样	固定 T=1.0、top_p=0.95	推荐 T=1.0	—
单价（美元/百万 token，输入 / 缓存 / 输出）	2 / 0.2 / 10，无峰谷	0.3 / 0.006 / 1.2，谷时半价	1.32 / 0.044 / 3.96，谷时半价

1.1 Kimi K3.1 Pro

- 变更：在 K3 上大幅增加后训练算力，覆盖数百个领域联合 RL；重做 RL 框架、长上下文推理、沙箱、rollout 调度。
- 官方提升方向：编程、3D 建模（直接写 Blender / CAD 脚本）、金融研究（内部 Financial Research

比 K3 高 11.6 分)、智能体。

- 安全：中期训练与 RL 数据剔除网络安全内容；xdev-bench-hard pass@3 81.0%（不剔除 90.5%）。
- 高速版 `kimi-k3.1-pro-highspeed`：速度 2–3 倍，价格 2 倍。K2 系列 2026 年底下线。
- 使用限制：充值 ≥1 美元解锁；累计充值决定并发 / TPM；temperature、top_p、n、penalty 不可传。
- 官方文档中的编程基准分数为占位符（"[xx.x%]"），无可引用数据。

1.2 DeepSeek-V4.1-Flash

- 2026-09-10 发布：20 层因果编码器 + 20 层解码器；MoE 1 共享 + 384 路由专家，每 token 激活 6 个；KV 缓存 890 字节/token，HBM 为上一代 1/4、SSD 为 1/8；原生视觉；降价；V4-Flash 下线。
- 2026-10-17 更新为 1017 版（新 / 旧）：Terminal-Bench 4.0 42.3 / 31.2，DeepSWE v1.1 77.0 / 74.2，ProgramBench 29.1 / 20.3，NL2Repo 68.2 / 65.4，HLE 42.6 / 36.8；输出更短、耗时更少；价格与调用方式不变。
- Codeforces 3471（max 档；同表 V4-Pro 3348)。输出单价为 V4-Pro 的 30%、Kimi K3.1 Pro 的 12%。

1.3 DeepSeek-V4-Pro

- 2026-04-24 首发; 2026-08-13 GA: HLE 42.7 / 60.0 (无 / 有工具), Terminal-Bench 2.1 87.9, DeepSWE 62.7，NL2Repo 61.5，Toolathlon-Verified 74.1；引入 low/high/max 三档；2026-08-16 起峰谷定价。
- V4.1-Flash 新闻稿称 9 月 14 日起该模型名改由 V4.1-Flash 承接，更新日志称继续提供、计费不变。本次 API 返回模型名 `deepseek-v4-pro`，按 V4-Pro 单价扣费（见 4.4)。
- 仅文本输入；单价为 V4.1-Flash 的 3.3 倍；DeepSeek 自报多数基准低于 V4.1-Flash。

2 评测方法

项目	设置
评测集	LiveCodeBench release_v6（ICLR 2025），官方提示词、官方判题，隐藏用例全过才算通过
指标	pass@1，每题 1 次
调用	官方 API；`BAI-AI-Lab/codingBench`，`cb livecodebench`
思考档位	各模型默认（Kimi max，DeepSeek high）
采样	DeepSeek：temperature 0.2（LCB 官方）；Kimi：固定 1.0
输出上限	DeepSeek 262,144；Kimi 131,072（默认）；全部回答正常结束（finish_reason=stop），无截断
并发	V4.1-Flash 16，V4-Pro 8；Kimi 前 32 题 4 路非流式，后 3 题 1 路流式（5 分钟无 token 判超时）；延迟含服务端排队
计量	每次调用记录起止时间与服务端返回的 token（含思考）
费用	官方单价 × token，DeepSeek 按调用时段区分峰谷；用账户余额变化核对
复核	LCB 判为失败的答案用真实 stdin/stdout 重跑官方测试，多解题用校验器判定（见 4.2）

3 评测题目

3.1 分布

release_v6 最新 100 题中，按难度各取最新：中等 10、困难 25；发布于 2025-03-15 至 2025-04-06。

难度	AtCoder	LeetCode	合计
中等	7	3	10
困难	19	6	25
合计	26	9	35

来源	题数	形式
AtCoder ABC 397–400	17	完整程序，标准输入输出
AtCoder ARC 195–196	9	完整程序，标准输入输出
LeetCode 周赛 / 双周赛	9	补全给定 Python 函数

3.2 示例

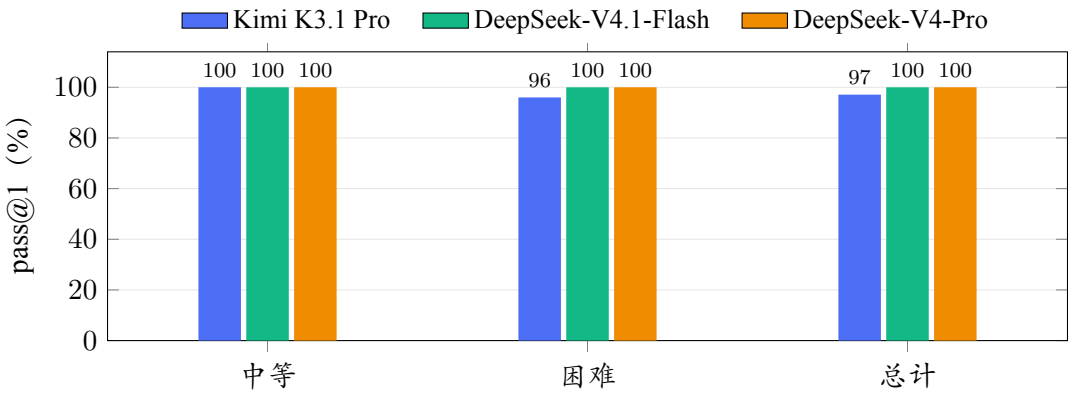
题目	内容
ABC 400 C “2^a b^2” 中等， 2025-04-05	**题意**：$X = 2^a b^2$（$a, b \geq 1$）为好数；给定 $N \leq 10^{18}$，求 $[1, N]$ 内好数个数。$N = 20$ 时为 5（2, 4, 8, 16, 18）。 **考点**：好数恰为 $2m^2$ 或 $4m^2$ 两类且互不重叠，答案 $\lfloor\sqrt{N/2}\rfloor + \lfloor\sqrt{N/4}\rfloor$；须用整数开方，浮点 `sqrt` 在 10^{18} 附近出错。 **结果**：Kimi ✓，2.3k token，35 秒；DS-Flash ✓，1.3k token，7 秒；DS-Pro ✓，3.4k token，25 秒
ARC 195 D “Swap and Erase” 困难， 2025-03-23	**题意**：可交换相邻元素，或删除开头一段全部相等的前缀；求删空序列的最少操作数。$T \leq 10^5$，$\sum N \leq 2 \times 10^5$。 **考点**：交换与删除的组合优化，须近线性时间。样例：$(1, 1, 2, 1, 2)$ 为 3（1 次交换 + 2 次删除），$(4, 2, 1, 3)$ 为 4（不交换）。 **结果**：Kimi ✓，86.5k token，1089 秒；DS-Flash ✓，81.0k token，475 秒；DS-Pro ✓，110.3k token，815 秒
LeetCode 3801 “Count Beautiful Numbers” 困难， 2025-03-15	**题意**：各位数字之积能被各位数字之和整除的正整数为美丽数；给定 $1 \leq l \leq r < 10^9$，求区间内个数。补全 `beautifulNumbers(self, l, r)`。 **考点**：数位 DP；含 0 时积为 0 必满足，否则积为 $2^a 3^b 5^c 7^d$，状态有限；暴力枚举超时。 **结果**：Kimi ✓，6.4k token，99 秒；DS-Flash ✓，3.8k token，22 秒；DS-Pro ✓，66.3k token，474 秒

4 评测结果

4.1 总表

指标	Kimi K3.1 Pro	DS-V4.1-Flash	DS-V4-Pro
通过：LCB 原始判分	30（85.7%）	30（85.7%）	**32（91.4%）**
通过：复核后（总计 35）	34（97.1%）	**35（100.0%）**	**35（100.0%）**
中等（10）	**10**	**10**	**10**
困难（25）	24	**25**	**25**
AtCoder（26）	25	**26**	**26**
LeetCode（9）	**9**	**9**	**9**
实际作答题数	35	35	35
有效运行时间（分钟）	143	**9**	49
每题延迟中位数（秒）	199	**64**	285
每题延迟 P90（秒）	1089	**327**	834
每题延迟最长（秒）	1888	**475**	1378
输出速度中位数（token/秒）	65	**179**	134
输出 token 合计	852k	644k	1.67M
其中思考 token 占比	98%	97%	99%
每题输出 token 中位数	14k	**12k**	38k
输入 token 合计（缓存命中）	24k（0k）	22k（16k）	24k（0k）
费用（美元，按 token 计）	$8.57	**$0.39**	$3.33
每道通过题的费用（美元）	$0.252	**$0.011**	$0.095
API 出错次数	31	0	13

粗体为该行最优；按难度、来源的通过数均为复核后结果。1 题 = 2.9 个百分点。有效运行时间 = 成功请求覆盖的时长（不含因余额不足暂停的时间）。API 出错：DS-V4-Pro 13 次为余额不足（402）；Kimi 30 次为挂起请求被切断后的连接错误，1 次为余额不足（429）。



4.2 LCB 判分问题与复核

问题	受影响答案	LCB 判定	复核
测试数据错误：`abc397_d` 第 41 个测试 $N = 27$，标准答案为“3 0”；$y = 0$ 不是正整数，27 不存在正整数解，正确输出为 −1	三个模型（均输出 −1）	答案错误	校验器 43/43
多解题按单一答案比对：`arc195_c` 允许任意合法构造	三个模型	答案错误	校验器 5/5
`sys.stdin.buffer.readline` 模拟错误：每次都返回输入的第一行	Flash `abc399_c`、`arc196_b`；Pro `arc196_b`	答案错误 / 运行错误	真实输入全部通过
不支持 `sys.stdout.buffer`：标准输出被替换为 StringIO	Kimi、Flash `abc398_f`	运行错误	真实输出 43/43
API 返回与题目无关的拒答（内容是一部电影的营销手法）	Kimi `abc399_e`	无代码	用户另行运行，确认正确

复核方法：26 道 AtCoder 题 × 3 个模型 = 78 份答案，作为独立 Python 进程用真实 stdin/stdout 运行官方全部测试（每个测试 6 秒）。两道多解题用按题意编写的校验器；其余题逐 token 比对。LCB 判为通过的答案复核后全部仍通过。LeetCode 9 题为函数调用，不受上述问题影响，沿用 LCB 判分。上述问题均出自 LCB 官方判题代码与数据（本评测钉住的版本），未修改。Kimi `abc398_g` 在 LCB 中报 IndexError，也是 readline 问题导致；换成真实输入后仍有 4/43 个测试答案错误，按失败计。

4.3 按难度

难度	模型	通过	延迟中位数（秒）	平均输出 token	最多输出 token
中等	Kimi K3.1 Pro	10/10	34	7k	27k
中等	DeepSeek-V4.1-Flash	10/10	8	10k	49k
中等	DeepSeek-V4-Pro	10/10	28	16k	64k
困难	Kimi K3.1 Pro	24/25	280	31k	119k
困难	DeepSeek-V4.1-Flash	25/25	79	22k	81k
困难	DeepSeek-V4-Pro	25/25	388	61k	174k

4.4 费用核对

- DS-V4.1-Flash：账户余额 ¥11.32 → ¥9.37，实扣 ¥1.95；按美元价目折算为 $0.39（人民币账户按人民币价目扣费）。
- DS-V4-Pro：按 token 计 $3.33（全部在谷时）。运行期间两次充值的金额未记录，无法用余额核对。13 次调用因余额不足立即返回 402，不生成内容，充值后补跑。

- Kimi K3.1 Pro：三次充值共 $17.50，最终余额 −$0.09，实扣 $17.59。成功返回的 35 次调用按 token 计 $8.57。差额 $9.02（由余额变化推算）对应 7 个未返回结果的请求：4 个在余额耗尽后挂起 1–1.5 小时，3 个被手动中断。

4.5 分析

- 复核后唯一的真实错误：Kimi `abc398_g`（博弈题），思考 11.9 万 token、耗时 31 分钟后，在 4/43 个测试上答案错误。这题 DS-V4.1-Flash 用 6.3 万 token、DS-V4-Pro 用 17.4 万 token 都做对了。
- 推理量：每题输出 token 中位数 DS-V4.1-Flash 12k、Kimi 14k、DS-V4-Pro 38k；困难题平均分别为 22k、31k、61k。DS-V4-Pro 多用的 token 没有换来更多通过题。
- 调用稳定性：DeepSeek 余额不足时立即返回 402，补跑即可，已答结果不丢。Kimi 非流式请求在余额耗尽后挂起 1–1.5 小时，既不返回也不报错；改为流式 + 5 分钟空闲超时后，最后 3 题单路完成（每题 20–31 分钟）。
- LCB 原始判分的误差：在这 35 题上，原始判分把 Flash 和 Pro 都低估了，Flash 少算 5 题、Pro 少算 3 题，而且两者的排序也被颠倒（原始 Pro 领先 2 题，复核后持平）。凡是用 LCB 判分做模型对比，都应复核失败题。

4.6 逐题结果

每个模型：结果（复核后）/ 输出 token（含思考）/ 延迟（秒）。* LCB 判为失败，复核后通过；† 评测中 API 返回无关内容，用户另行运行确认正确，按通过计。

题号	题目	难度	Kimi K3.1 Pro			DS-V4.1-Flash			DS-V4-Pro	
`abc398_b`	Full House 3	中	✓	0.9k	15	✓	0.3k	3	✓	1.0k	7
`abc398_c`	Uniqueness	中	✓	0.4k	5	✓	0.4k	3	✓	0.4k	4
`arc195_a`	Twice Subsequence	中	✓	2.2k	34	✓	2.9k	16	✓	18.4k	144
`abc399_c`	Make it Forest	中	✓	0.5k	8	✓*	0.5k	3	✓	0.4k	4
`abc399_d`	Switch Seats	中	✓	25.4k	409	✓	26.8k	149	✓	38.2k	282
`abc400_c`	2^a b^2	中	✓	2.3k	35	✓	1.3k	7	✓	3.4k	25
`abc400_d`	Takahashi the Wall Breaker	中	✓	26.7k	416	✓	49.0k	290	✓	63.9k	544
`3809`	properties-graph	中	✓	0.6k	10	✓	0.4k	3	✓	1.1k	8
`3805`	maximize-active-section-w…	中	✓	7.5k	94	✓	13.4k	75	✓	27.9k	208
`3793`	longest-palindrome-after-…	中	✓	2.7k	44	✓	1.5k	9	✓	4.0k	30
`abc397_d`	Cubes	难	✓*	3.3k	49	✓*	5.0k	25	✓*	26.4k	179
`abc397_e`	Path Decomposition of a T…	难	✓	26.7k	451	✓	15.6k	95	✓	42.5k	332
`abc397_f`	Variety Split Hard	难	✓	64.0k	944	✓	21.4k	107	✓	55.9k	403
`abc397_g`	Maximize Distance	难	✓	33.1k	423	✓	14.5k	76	✓	55.8k	423
`abc398_d`	Bonfire	难	✓	4.4k	74	✓	2.8k	16	✓	10.8k	80
`abc398_f`	ABCBA	难	✓*	6.4k	97	✓*	1.7k	9	✓	38.2k	285
`abc398_g`	Not Only Tree Game	难	✗答案错误	118.7k	1888	✓	63.4k	327	✓	174.0k	1378
`arc195_b`	Uniform Sum	难	✓	54.6k	924	✓	16.7k	96	✓	55.7k	454
`arc195_c`	Hamiltonian Pieces	难	✓*	20.9k	322	✓*	22.4k	120	✓*	64.1k	453
`arc195_d`	Swap and Erase	难	✓	86.5k	1089	✓	81.0k	475	✓	110.3k	815
`arc195_e`	Random Tree Distance	难	✓	11.7k	176	✓	11.6k	64	✓	37.9k	256
`abc399_e`	Replace	难	✓†	2.8k	51	✓	26.3k	164	✓	55.0k	463
`abc399_f`	Range Power Sum	难	✓	2.5k	38	✓	2.5k	12	✓	6.6k	51
`abc400_e`	Ringo's Favorite Numbers 3	难	✓	3.1k	47	✓	3.1k	16	✓	10.2k	79

题号	题目	难度	Kimi K3.1 Pro			DS-V4.1-Flash			DS-V4-Pro		
abc400_g	Patisserie ABC 3	难	43.4k	735	✓	55.0k	334	✓	112.7k	941	✓
arc196_a	Adjacent Delete	难	33.4k	536	✓	18.3k	98	✓	48.3k	351	✓
arc196_b	Torus Loop	难	16.9k	280	✓*	22.7k	121	✓*	67.9k	496	✓
arc196_c	Strongly Connected	难	105.4k	1730	✓	76.8k	439	✓	164.2k	1221	✓
arc196_d	Roadway	难	68.1k	1230	✓	43.0k	248	✓	110.4k	834	✓
3784	longest-common-prefix-of-…	难	20.5k	296	✓	8.9k	50	✓	49.4k	368	✓
3801	count-beautiful-numbers	难	6.4k	99	✓	3.8k	22	✓	66.3k	474	✓
3744	minimum-operations-to-mak…	难	14.1k	220	✓	5.9k	33	✓	34.9k	250	✓
3765	minimum-cost-to-divide-ar…	难	6.5k	80	✓	3.5k	19	✓	35.1k	259	✓
3717	minimum-operations-to-mak…	难	14.1k	214	✓	7.6k	40	✓	30.1k	215	✓
3777	maximum-product-of-subseq…	难	15.2k	199	✓	13.9k	79	✓	50.8k	388	✓

5 局限

- 35 题、每题 1 次：相差 1–2 题不显著；两个 DeepSeek 模型均为满分，这批题已不足以区分二者。
- 采样温度不同：DeepSeek 0.2，Kimi 固定 1.0。
- 延迟受并发和服务端负载影响。
- 题目早于三个模型发布，不排除训练数据污染。
- 复核后的成绩依赖本报告的重判程序和校验器；LCB 原始判分同时列出，可对照。
- Kimi abc399_e 按用户另行运行的结果计为通过，未在本评测流程中复现。

来源

- Kimi：https://platform.kimi.ai/docs/guide/kimi-k3-1-pro-quickstart，https://platform.kimi.ai/docs/models，https://platform.kimi.ai/docs/pricing/chat
- DeepSeek：https://api-docs.deepseek.com/updates/，https://www.deepseek.com/en/news/deepseek-v4-1-flash/，https://huggingface.co/deepseek-ai/DeepSeek-V4.1-Flash，https://api-docs.deepseek.com/quick_start/pricing
- 上下文、最大输出、默认档位：两家 API /v1/models（2026-10-23）
- LiveCodeBench：https://livecodebench.github.io