阶梯代码评测报告

DeepSeek Flash V4.1-1017

2026-10-28　L1–L4：USACO 2024–26 与 EGOI/IOI 2026；L5：FrontierCS 算法赛道

1　评测维度与打分标准

各维度分开报告，不合成总分；表格中↑越大越好，↓越小越好，没有箭头的只作描述。

维度	指标	计算方法	方向
正确性	测试点得分 s_t	每个测试点 0–1：USACO 忽略空白逐 token 比对，相同为 1、否则 0；EGOI、IOI 取官方 checker 给出的 0–1 分；FrontierCS 取官方 checker 输出的 Ratio（达到参考解为 0.6，超过参考解按对数加分，最高 1）。程序编译失败、运行出错、超时或超内存，该测试点为 0。	
正确性	题目得分 S（0–100）	USACO：$S = 100 \cdot \frac{1}{T}\sum_t s_t$（每个测试点等分）；EGOI、IOI：$S = 100 \cdot \frac{\sum_g w_g \min_{t\in g} s_t}{\sum_g w_g}$（子任务 g 取其中测试点的最低分，再乘以子任务分值 w_g）；FrontierCS：$S = 100 \cdot \frac{1}{T}\sum_t \mathrm{Ratio}_t$。	↑
正确性	解出	所有测试点 $s_t = 1$。	
正确性	pass@1、平均得分、pass@n	pass@1 = 解出的采样数 ÷ 采样总数 × 100；平均得分 = 所有采样的 S 的平均；pass@n = 至少一次采样解出的题数 ÷ 题数 × 100。每档采样次数：L1、L2、L5 各 1 次，L3、L4 各 3 次，temperature 0.2。	↑
正确性 / 效率	宽时限与官方时限	每个测试点只运行一次，时限为官方时限的 5 倍（宽时限）。宽时限口径：按上面的规则计分。官方时限口径：CPU 时间超过官方时限的测试点记 0，再按同样的规则算 S、pass@1。前者回答“算法对不对”，后者回答“是否和人类选手一样在时限内通过”。	↑
效率	运行时间倍数	只对解出的答案、且官方解在某个测试点上至少需要 0.05 秒 CPU 的题：取官方解最慢的 3 个测试点，答案与官方解交替各运行 3 次取中位数，r = 答案 CPU 时间 ÷ 官方解 CPU 时间（取官方解最慢的那个测试点）；各档报告 r 的几何平均和题数。同语言比较。	↓
效率	内存倍数	解出的答案在所有测试点上的峰值内存 ÷ 官方解的峰值内存，各档取几何平均。	↓

维度	指标	计算方法	方向
复杂度	相对官方解的增长幂次 k	官方测试不是按规模排列的序列（USACO 里耗时较长的测试点大多都是最大规模），所以以官方解自己的工作量为横轴：在官方解至少需要 2 ms CPU（扣除空程序）的测试点上（最多 20 个，均匀覆盖其耗时范围），答案与官方解交替各运行 5 次取中位数，拟合 $\log y_{\text{答案}} = a + k \log y_{\text{官方}}$。若官方解为 $\Theta(f(n))$、答案为 $\Theta(f(n)^k)$，k 即该指数。$R^2 \geq 0.8$ 时：$k \leq 0.75$ 且在官方解最重的 3 个测试点上答案至少快 2 倍为更优（列出供人工复核），$0.75 < k < 1.33$ 为同阶，$k \geq 1.33$ 且在这些测试点上至少慢 2 倍为更差；$R^2 < 0.8$，或斜率与最重测试点上的快慢对不上（某一方有固定开销会把斜率拉偏），为不确定；可用测试点少于 4 个或官方耗时跨度不足 4 倍为不可测。空间同理（峰值内存，至少高于空程序 1 MB）。这些测试点的输入大小跨度达到 8 倍时，另报两者按输入大小的增长幂次。	
失败类型	每份未解出答案的主要原因	按顺序取第一个成立的：无代码、编译错误、答案错误、运行错误、超内存、超时、部分分（部分测试点得分）；宽时限下解出但官方时限下没有全部通过的记为“只在官方时限下超时”。FrontierCS 为连续分，得分大于 0 的答案记为部分分，只有 0 分的答案按上面的顺序找原因。	
静态质量	Pylint、Radon、SonarQube（只限 L1–L2 的 Python 答案）	按 arXiv:2610.19167 的口径与版本：Pylint 3.3.5 默认配置的问题数（C/R/W/E）与 0–10 分，Radon 6.0.1 的圈复杂度（所有条目之和）、可维护性指数 MI、SLOC，SonarQube 10.4 的可维护性/可靠性/安全问题数；报告正确答案的每份平均与每百行 SLOC 的问题数。	见表头
成本与时延	token、费用、延迟、首个 token 时间	费用 = (输入 − 缓存命中) × 输入单价 + 缓存命中 × 命中单价 + 输出（含思考）× 输出单价，单价按每百万 token，分时计价按每次调用的开始时间；延迟为每次调用从发出到收完的时间。	↓
泄露检查	2026 子集与 USACO 子集	L3、L4 中 EGOI/IOI 2026 新题与同档 USACO 旧题分开报告 pass@1 与平均得分；新题明显更差时提示旧题可能见过。只作提示，不作结论。	

2 各档正确率

			pass@1 ↑		平均得分 ↑		
档位	题数	采样数	宽时限	官方时限	宽时限	官方时限	pass@n ↑
L1 基础	18	18	100.0	94.4	100.0	97.0	–
L2 中等	19	19	94.7	94.7	95.2	95.2	–
L3 困难	20	60	96.7	96.7	97.8	97.8	100.0
L4 顶尖	8	24	70.8	70.8	75.3	75.3	87.5

宽时限 = 官方时限的 5 倍，看算法对不对；官方时限看能否像人类选手一样在时限内通过。pass@n = 每题多次采样中至少解出一次的题目比例（L3 每题 3 次、L4 每题 3 次）；每题只采样 1 次的档记

“–”。

3 2026 新题与 USACO 旧题对照

同一档内 2026 年新题与 USACO 旧题分开统计（宽时限）。难度相当而新题明显更差时，旧题成绩可能受训练数据泄露抬高；只作提示，不作结论。本次评测还没有 2026 年的 EGOI/IOI 题，下表只是 USACO 两个赛季之间的对照（2025-26 赛季的题更新）。

档位	子集	题数	采样数	pass@1 ↑	平均得分 ↑
L3 困难	USACO 2024-25	12	36	97.2	98.9
L3 困难	USACO 2025-26	8	24	95.8	96.1
L4 顶尖	USACO 2024-25	8	24	70.8	75.3

4 代码性能（相对官方解，同语言）

只比较解出的答案：在官方解最慢的 3 个测试点上与官方解交替各运行 3 次取中位数，倍数 = 答案 ÷ 官方解，各档取几何平均；小于 1 表示比官方解快。EGOI、FrontierCS 没有官方解，不参与。

档位	比较的答案数	CPU 时间倍数 ↓	快于官方解（份）	慢 2 倍以上（份）	峰值内存倍数 ↓
L1 基础	11	0.54×	10	1	0.96×
L2 中等	7	0.93×	5	1	1.25×
L3 困难	52	0.63×	42	5	0.95×
L4 顶尖	14	1.10×	8	3	0.89×

5 时间与空间复杂度（相对官方解）

k 为答案耗时（或峰值内存）相对官方解的增长幂次：$k \le 0.75$ 且在官方解最重的测试点上至少快 2 倍为更优（可能是更好或更新颖的解法），$0.75 < k < 1.33$ 为同阶，$k \ge 1.33$ 且至少慢 2 倍为更差，其余为不确定；方法见“评测维度与打分标准”。

时间复杂度

	答案数						
档位	更优	同阶	更差	不确定	不可测	无官方解	k 中位数
L1 基础	1	8	0	3	0	6	0.93
L2 中等	1	7	0	0	0	10	0.95
L3 困难	5	29	1	5	18	0	0.99
L4 顶尖	0	4	0	1	9	3	1.08

空间复杂度

	答案数						
档位	更优	同阶	更差	不确定	不可测	无官方解	k 中位数
L1 基础	0	1	0	2	9	6	0.96
L2 中等	0	3	0	0	5	10	0.99
L3 困难	0	0	0	9	49	0	–
L4 顶尖	0	1	0	1	12	3	1.30

增长慢于官方解、值得人工复核的答案

档位	答案	维度
L1 基础	usaco-1444#0	时间
L2 中等	usaco-1496#0	时间
L3 困难	usaco-1498#1	时间
L3 困难	usaco-1498#2	时间
L3 困难	usaco-1521#1	时间
L3 困难	usaco-1521#2	时间
L3 困难	usaco-1547#0	时间

6 失败类型（答案数）

每份答案只记一个主要原因（判定顺序见“评测维度与打分标准”）。“只在官方时限下超时”的答案在宽时限下是解出的，单列。

			未解出的主要原因				
档位	答案数	未解出	无代码	编译错误	答案错误	运行错误	只在官方时限下超时
L1 基础	18	0	0	0	0	0	1
L2 中等	19	1	0	0	1	0	0
L3 困难	60	2	0	0	2	0	0
L4 顶尖	24	7	1	1	4	1	0

7 静态质量（L1–L2，Python）

只统计解出的 Python 答案（L1、L2），每份答案的平均值；工具与版本按 arXiv:2610.19167。

		Pylint			Radon		
档位	答案数	问题数↓	得分↑	每百行问题数↓	圈复杂度↓	可维护性 MI↑	SLOC
L1 基础	18	6.67	8.47	15.31	11.72	53.0	43.6
L2 中等	18	11.56	8.64	13.62	23.39	44.2	84.8
合计	36	9.11	8.55	14.19	17.56	48.6	64.2

	SonarQube 10.4		
档位	可维护性问题↓	可靠性问题↓	安全问题↓
L1 基础	1.06	0.00	0.00
L2 中等	2.00	0.00	0.00
合计	1.53	0.00	0.00

8 用量与费用

调用数只计拿到回答的调用；输出 token 含思考过程；延迟为一次调用从发出到收完的时间；费用按每次调用开始时的分时单价计算。

档位	调用数	输出 token↓	每次输出 token↓	延迟中位数↓	费用↓
L1 基础	18	184.9k	10.3k	59 s	$0.11
L2 中等	19	620.3k	32.6k	155 s	$0.37
L3 困难	60	1.84M	30.6k	152 s	$1.11
L4 顶尖	24	1.70M	70.7k	312 s	$1.02
合计	121	4.34M	35.9k	150 s	$2.61

9 逐题结果

题目	名称	档位	子集	解出 / 采样	平均得分↑	主要失败
usaco-1443	Roundabout Rounding	L1	2024-25	1/1	100.0	
usaco-1444	Farmer John’s Cheese Block	L1	2024-25	1/1	100.0	
usaco-1445	It’s Mooin’ Time	L1	2024-25	1/1	100.0	
usaco-1467	Astral Superposition	L1	2024-25	1/1	100.0	
usaco-1468	It’s Mooin’ Time II	L1	2024-25	1/1	100.0	
usaco-1469	Cow Checkups	L1	2024-25	1/1	100.0	只在官方时限下超时
usaco-1491	Reflection	L1	2024-25	1/1	100.0	
usaco-1492	Making Mexes	L1	2024-25	1/1	100.0	
usaco-1493	Printing Sequences	L1	2024-25	1/1	100.0	

题目	名称	档位	子集	解出 / 采样	平均得分↑	主要失败
usaco-1515	Hoof Paper Scissors Minus One	L1	2024-25	1/1	100.0	
usaco-1516	More Cow Photos	L1	2024-25	1/1	100.0	
usaco-1517	It’s Mooin’ Time III	L1	2024-25	1/1	100.0	
usaco-1539	Chip Exchange	L1	2025-26	1/1	100.0	
usaco-1541	Photoshoot	L1	2025-26	1/1	100.0	
usaco-1564	Moo Hunt	L1	2025-26	1/1	100.0	
usaco-1565	Purchasing Milk	L1	2025-26	1/1	100.0	
usaco-1587	Make All Distinct	L1	2025-26	1/1	100.0	
usaco-1588	Strange Function	L1	2025-26	1/1	100.0	
usaco-1446	Cake Game	L2	2024-25	0/1	9.1	答案错误
usaco-1447	Deforestation	L2	2024-25	1/1	100.0	
usaco-1448	2D Conveyor Belt	L2	2024-25	1/1	100.0	
usaco-1470	Cow Checkups	L2	2024-25	1/1	100.0	
usaco-1471	Farmer John’s Favorite Operation	L2	2024-25	1/1	100.0	
usaco-1472	Table Recovery	L2	2024-25	1/1	100.0	
usaco-1494	The Best Lineup	L2	2024-25	1/1	100.0	
usaco-1495	Vocabulary Quiz	L2	2024-25	1/1	100.0	
usaco-1496	Transforming Pairs	L2	2024-25	1/1	100.0	
usaco-1519	Compatible Pairs	L2	2024-25	1/1	100.0	
usaco-1520	Ski Slope	L2	2024-25	1/1	100.0	
usaco-1542	Lineup Queries	L2	2025-26	1/1	100.0	
usaco-1543	Mooclear Reactor	L2	2025-26	1/1	100.0	
usaco-1544	Sliding Window Summation	L2	2025-26	1/1	100.0	
usaco-1567	Declining Invitations	L2	2025-26	1/1	100.0	
usaco-1568	Farmer John Loves Rotations	L2	2025-26	1/1	100.0	
usaco-1590	Clash!	L2	2025-26	1/1	100.0	
usaco-1591	Milk Buckets	L2	2025-26	1/1	100.0	
usaco-1592	Point Elimination	L2	2025-26	1/1	100.0	
usaco-1449	Cowdependence	L3	2024-25	2/3	86.7	答案错误
usaco-1450	Interstellar Intervals	L3	2024-25	3/3	100.0	
usaco-1451	Job Completion	L3	2024-25	3/3	100.0	
usaco-1473	Median Heap	L3	2024-25	3/3	100.0	
usaco-1474	Reachable Pairs	L3	2024-25	3/3	100.0	
usaco-1475	Photo Op	L3	2024-25	3/3	100.0	
usaco-1497	Bessie’s Function	L3	2024-25	3/3	100.0	
usaco-1498	The Best Subsequence	L3	2024-25	3/3	100.0	
usaco-1499	Friendship Editing	L3	2024-25	3/3	100.0	
usaco-1521	Moo Decomposition	L3	2024-25	3/3	100.0	
usaco-1522	Election Queries	L3	2024-25	3/3	100.0	

题目	名称	档位	子集	解出 / 采样	平均得分↑	主要失败
usaco-1523	OohMoo Milk	L3	2024-25	3/3	100.0	
usaco-1545	COW Traversals	L3	2025-26	3/3	100.0	
usaco-1546	Milk Buckets	L3	2025-26	2/3	69.0	答案错误
usaco-1547	Supervision	L3	2025-26	3/3	100.0	
usaco-1569	Balancing the Barns	L3	2025-26	3/3	100.0	
usaco-1570	Lexicographically Smallest Path	L3	2025-26	3/3	100.0	
usaco-1571	The Chase	L3	2025-26	3/3	100.0	
usaco-1593	Good Cyclic Shifts	L3	2025-26	3/3	100.0	
usaco-1595	Random Tree Generation	L3	2025-26	3/3	100.0	
usaco-1452	All Pairs Similarity	L4	2024-25	3/3	100.0	
usaco-1453	It’s Mooin’ Time	L4	2024-25	3/3	100.0	
usaco-1454	Maximize Minimum Difference	L4	2024-25	0/3	10.0	答案错误
usaco-1476	DFS Order	L4	2024-25	3/3	100.0	
usaco-1477	Shock Wave	L4	2024-25	1/3	35.7	编译错误
usaco-1502	True or False Test	L4	2024-25	3/3	100.0	
usaco-1525	Lazy Sort	L4	2024-25	3/3	100.0	
usaco-1526	Package Pickup	L4	2024-25	1/3	56.7	运行错误

由 Albert Huang 创建于 2026-10-28