阶梯代码评测报告

deepseek-flash

2026-10-28　L1–L4：USACO 2024–26 与 EGOI/IOI 2026；L5：FrontierCS 算法赛道

1　评测维度与打分标准

各维度分开报告，不合成总分；表格中↑越大越好，↓越小越好，没有箭头的只作描述。

维度	指标	计算方法	方向
正确性	测试点得分 s_t	每个测试点 0–1：USACO 忽略空白逐 token 比对，相同为 1、否则 0；EGOI、IOI 取官方 checker 给出的 0–1 分；FrontierCS 取官方 checker 输出的 Ratio（达到参考解为 0.6，超过参考解按对数加分，最高 1）。程序编译失败、运行出错、超时或超内存，该测试点为 0。	
正确性	题目得分 S（0–100）	USACO：$S = 100 \cdot \frac{1}{T}\sum_t s_t$（每个测试点等分）；EGOI、IOI：$S = 100 \cdot \frac{\sum_g w_g \min_{t\in g} s_t}{\sum_g w_g}$（子任务 g 取其中测试点的最低分，再乘以子任务分值 w_g）；FrontierCS：$S = 100 \cdot \frac{1}{T}\sum_t \mathrm{Ratio}_t$。	↑
正确性	解出	所有测试点 $s_t = 1$。	
正确性	pass@1、平均得分、pass@n	pass@1 = 解出的采样数 ÷ 采样总数 × 100；平均得分 = 所有采样的 S 的平均；pass@n = 至少一次采样解出的题数 ÷ 题数 × 100。每档采样次数：L1、L2、L5 各 1 次，L3、L4 各 3 次，temperature 0.2。	↑
正确性 / 效率	宽时限与官方时限	每个测试点只运行一次，时限为官方时限的 5 倍（宽时限）。宽时限口径：按上面的规则计分。官方时限口径：CPU 时间超过官方时限的测试点记 0，再按同样的规则算 S、pass@1。前者回答“算法对不对”，后者回答“是否和人类选手一样在时限内通过”。	↑
效率	运行时间倍数	只对解出的答案、且官方解在某个测试点上至少需要 0.05 秒 CPU 的题：取官方解最慢的 3 个测试点，答案与官方解交替各运行 3 次取中位数，r = 答案 CPU 时间 ÷ 官方解 CPU 时间（取官方解最慢的那个测试点）；各档报告 r 的几何平均和题数。同语言比较。	↓
效率	内存倍数	解出的答案在所有测试点上的峰值内存 ÷ 官方解的峰值内存，各档取几何平均。	↓
复杂度	相对官方解的增长幂次 k	官方测试不是按规模排列的序列（USACO 里耗时较长的测试点大多都是最大规模），所以以官方解自己的工作量为横轴：在官方解至少需要 2 ms CPU（扣除空程序）的测试点上（最多 20 个，均匀覆盖其耗时范围），答案与官方解交替各运行 5 次取中位数，拟合 $\log y_{\text{答案}} = a + k \log y_{\text{官方}}$。若官方解为 $\Theta(f(n))$、答案为 $\Theta(f(n)^k)$，k 即该指数。$R^2 \geq 0.8$ 时：$k \leq 0.75$ 且在官方解最重的 3 个测试点上答案至少快 2 倍为更优（列出供人工复核），$0.75 < k < 1.33$ 为同阶，$k \geq 1.33$ 且在这些测试点上至少慢 2 倍为更差；$R^2 < 0.8$，或斜率与最重测试点上的快慢对不上（某一方有固定开销会把斜率拉偏），为不确定；可用测试点少于 4 个或官方耗时跨度不足 4 倍为不可测。空间同理（峰值内存，至少高于空程序 1 MB）。这些测试点的输入大小跨度达到 8 倍时，另报两者按输入大小的增长幂次。	

维度	指标	计算方法	方向
失败类型	每份未解出答案的主要原因	按顺序取第一个成立的：无代码、编译错误、答案错误、运行错误、超内存、超时、部分分（部分测试点得分）；宽时限下解出但官方时限下没有全部通过的记为“只在官方时限下超时”。	
静态质量	Pylint、Radon、SonarQube（只限 L1–L2 的 Python 答案）	按 arXiv:2610.19167 的口径与版本：Pylint 3.3.5 默认配置的问题数（C/R/W/E）与 0–10 分，Radon 6.0.1 的圈复杂度（所有条目之和）、可维护性指数 MI、SLOC，SonarQube 10.4 的可维护性/可靠性/安全问题数；报告正确答案的每份平均与每百行 SLOC 的问题数。	见表头
成本与时延	token、费用、延迟、首个 token 时间	费用 =(输入 − 缓存命中) × 输入单价 + 缓存命中 × 命中单价 + 输出（含思考）× 输出单价，单价按每百万 token，分时计价按每次调用的开始时间；延迟为每次调用从发出到收完的时间。	↓
泄露检查	2026 子集与 USACO 子集	L3、L4 中 EGOI/IOI 2026 新题与同档 USACO 旧题分开报告 pass@1 与平均得分；新题明显更差时提示旧题可能见过。只作提示，不作结论。	

2 各档正确率

档位与指标	deepseek-flash
L1 基础：pass@1 宽时限 ↑	100.0
L1 基础：pass@1 官方时限 ↑	94.4
L1 基础：得分宽时限 ↑	100.0
L1 基础：得分官方时限 ↑	97.0
L2 中等：pass@1 宽时限 ↑	94.7
L2 中等：pass@1 官方时限 ↑	94.7
L2 中等：得分宽时限 ↑	95.2
L2 中等：得分官方时限 ↑	95.2
L3 困难：pass@1 宽时限 ↑	96.7
L3 困难：pass@1 官方时限 ↑	96.7
L3 困难：得分宽时限 ↑	97.8
L3 困难：得分官方时限 ↑	97.8
L3 困难：pass@n ↑	100.0
L4 顶尖：pass@1 宽时限 ↑	70.8
L4 顶尖：pass@1 官方时限 ↑	70.8
L4 顶尖：得分宽时限 ↑	75.3
L4 顶尖：得分官方时限 ↑	75.3
L4 顶尖：pass@n ↑	87.5

3 2026 新题与 USACO 对照

同一档内，2026 年的新题（EGOI、IOI）与 USACO 旧题的 pass@1 / 平均得分。新题明显更低而难度相当时，旧题成绩可能受训练数据泄露抬高。本次评测还没有 2026 年的 EGOI/IOI 题，下表只是 USACO 两个赛季之间的对照（2025–26 赛季的题更新）。

档位 / 子集	deepseek-flash
L3 / USACO 2024-25	97.2 / 98.9
L3 / USACO 2025-26	95.8 / 96.1
L4 / USACO 2024-25	70.8 / 75.3

4 代码性能

解出的答案在官方解最慢的 3 个测试点上与官方解交替各跑 3 次取中位数；表中为答案 CPU 时间 ÷ 官方解（几何平均，括号内为答案份数）。

档位	deepseek-flash
L1 基础 ↓	0.54× (11)
L2 中等 ↓	0.93× (7)
L3 困难 ↓	0.63× (52)
L4 顶尖 ↓	1.10× (14)

5 时间与空间复杂度

k 为答案耗时（或内存）相对官方解的增长幂次：$k \le 0.75$ 且在官方解最重的测试点上至少快 2 倍为更优（可能是更好或更新颖的解法），$0.75 < k < 1.33$ 同阶，$k \ge 1.33$ 且至少慢 2 倍为更差，其余为不确定；方法见“评测维度与打分标准”。

档位	deepseek-flash
L1 基础：时间（更优/同阶/更差/不确定/不可测/无官方解）	1/8/0/3/0/6，k=0.93
L1 基础：空间（更优/同阶/更差/不确定/不可测/无官方解）	0/1/0/2/9/6，k=0.96
L2 中等：时间（更优/同阶/更差/不确定/不可测/无官方解）	1/7/0/0/0/10，k=0.95
L2 中等：空间（更优/同阶/更差/不确定/不可测/无官方解）	0/3/0/0/5/10，k=0.99
L3 困难：时间（更优/同阶/更差/不确定/不可测/无官方解）	5/29/1/5/18/0，k=0.99
L3 困难：空间（更优/同阶/更差/不确定/不可测/无官方解）	0/0/0/9/49/0，k=–
L4 顶尖：时间（更优/同阶/更差/不确定/不可测/无官方解）	0/4/0/1/9/3，k=1.08
L4 顶尖：空间（更优/同阶/更差/不确定/不可测/无官方解）	0/1/0/1/12/3，k=1.30

增长慢于官方解、值得人工复核的答案：deepseek-flash usaco-1444#0（时间）；deepseek-flash usaco-1496#0（时间）; deepseek-flash usaco-1498#1（时间）; deepseek-flash usaco-1498#2（时间）; deepseek-flash usaco-1521#1（时间）；deepseek-flash usaco-1521#2（时间）；deepseek-flash usaco-1547#0（时间）。

6 失败类型

档位与类型	deepseek-flash
L1 基础：只在官方时限下超时	1
L2 中等：答案错误	1
L3 困难：答案错误	2
L4 顶尖：无代码	1
L4 顶尖：编译错误	1
L4 顶尖：答案错误	4
L4 顶尖：运行错误	1

7 静态质量（L1–L2，Python）

指标（正确答案）	deepseek-flash
Pylint 问题数↓	9.11
Pylint 分↑	8.55
圈复杂度 CC↓	17.56
可维护性 MI↑	48.59
SLOC	64.19
每百行问题数↓	14.19
SonarQube 可维护性↓	1.53
SonarQube 可靠性↓	0.00
SonarQube 安全↓	0.00

8 用量与费用

指标	deepseek-flash
调用（出错）	182 (61)
输出 token↓	4.34M
延迟中位数↓	150 s
费用↓	$2.61

9 逐题结果

deepseek-flash

题目	档	解出/采样	得分	主要失败
usaco-1443 Roundabout Rounding	L1	1/1	100.0	

题目	档	解出/采样	得分	主要失败
usaco-1444 Farmer John’s Cheese Block	L1	1/1	100.0	
usaco-1445 It’s Mooin’ Time	L1	1/1	100.0	
usaco-1446 Cake Game	L2	0/1	9.1	答案错误
usaco-1447 Deforestation	L2	1/1	100.0	
usaco-1448 2D Conveyor Belt	L2	1/1	100.0	
usaco-1449 Cowdependence	L3	2/3	86.7	答案错误
usaco-1450 Interstellar Intervals	L3	3/3	100.0	
usaco-1451 Job Completion	L3	3/3	100.0	
usaco-1452 All Pairs Similarity	L4	3/3	100.0	
usaco-1453 It’s Mooin’ Time	L4	3/3	100.0	
usaco-1454 Maximize Minimum Difference	L4	0/3	10.0	答案错误
usaco-1467 Astral Superposition	L1	1/1	100.0	
usaco-1468 It’s Mooin’ Time II	L1	1/1	100.0	
usaco-1469 Cow Checkups	L1	1/1	100.0	只在官方时限下超时
usaco-1470 Cow Checkups	L2	1/1	100.0	
usaco-1471 Farmer John’s Favorite Operation	L2	1/1	100.0	
usaco-1472 Table Recovery	L2	1/1	100.0	
usaco-1473 Median Heap	L3	3/3	100.0	
usaco-1474 Reachable Pairs	L3	3/3	100.0	
usaco-1475 Photo Op	L3	3/3	100.0	
usaco-1476 DFS Order	L4	3/3	100.0	
usaco-1477 Shock Wave	L4	1/3	35.7	编译错误
usaco-1491 Reflection	L1	1/1	100.0	
usaco-1492 Making Mexes	L1	1/1	100.0	
usaco-1493 Printing Sequences	L1	1/1	100.0	
usaco-1494 The Best Lineup	L2	1/1	100.0	
usaco-1495 Vocabulary Quiz	L2	1/1	100.0	
usaco-1496 Transforming Pairs	L2	1/1	100.0	
usaco-1497 Bessie’s Function	L3	3/3	100.0	
usaco-1498 The Best Subsequence	L3	3/3	100.0	
usaco-1499 Friendship Editing	L3	3/3	100.0	
usaco-1502 True or False Test	L4	3/3	100.0	
usaco-1515 Hoof Paper Scissors Minus One	L1	1/1	100.0	
usaco-1516 More Cow Photos	L1	1/1	100.0	
usaco-1517 It’s Mooin’ Time III	L1	1/1	100.0	
usaco-1519 Compatible Pairs	L2	1/1	100.0	
usaco-1520 Ski Slope	L2	1/1	100.0	
usaco-1521 Moo Decomposition	L3	3/3	100.0	

题目	档	解出/采样	得分	主要失败
usaco-1522 Election Queries	L3	3/3	100.0	
usaco-1523 OohMoo Milk	L3	3/3	100.0	
usaco-1525 Lazy Sort	L4	3/3	100.0	
usaco-1526 Package Pickup	L4	1/3	56.7	运行错误
usaco-1539 Chip Exchange	L1	1/1	100.0	
usaco-1541 Photoshoot	L1	1/1	100.0	
usaco-1542 Lineup Queries	L2	1/1	100.0	
usaco-1543 Mooclear Reactor	L2	1/1	100.0	
usaco-1544 Sliding Window Summation	L2	1/1	100.0	
usaco-1545 COW Traversals	L3	3/3	100.0	
usaco-1546 Milk Buckets	L3	2/3	69.0	答案错误
usaco-1547 Supervision	L3	3/3	100.0	
usaco-1564 Moo Hunt	L1	1/1	100.0	
usaco-1565 Purchasing Milk	L1	1/1	100.0	
usaco-1567 Declining Invitations	L2	1/1	100.0	
usaco-1568 Farmer John Loves Rotations	L2	1/1	100.0	
usaco-1569 Balancing the Barns	L3	3/3	100.0	
usaco-1570 Lexicographically Smallest Path	L3	3/3	100.0	
usaco-1571 The Chase	L3	3/3	100.0	
usaco-1587 Make All Distinct	L1	1/1	100.0	
usaco-1588 Strange Function	L1	1/1	100.0	
usaco-1590 Clash!	L2	1/1	100.0	
usaco-1591 Milk Buckets	L2	1/1	100.0	
usaco-1592 Point Elimination	L2	1/1	100.0	
usaco-1593 Good Cyclic Shifts	L3	3/3	100.0	
usaco-1595 Random Tree Generation	L3	3/3	100.0	